

Министерство образования и науки Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ЯДЕРНЫЙ УНИВЕРСИТЕТ
«МИФИ»
(НИЯУ МИФИ)

ОТЧЕТ
О НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ
«Методика обнаружения несанкционированных действий и аномальной
активности в корпоративной сети с использованием нейронных сетей»

Исполнитель:

ст. группы №Б22-505

Д.И. Титов

подпись, дата

Научный руководитель:

Д.П. Ланской

подпись, дата

Зам. зав. кафедры № 42:

К.Г. Когос

подпись, дата

Москва 2026

РЕФЕРАТ

Отчет 72 с., 1 кн., 6 рис., 24 табл., 45 источн., 3 прил.

ОБНАРУЖЕНИЕ ВТОРЖЕНИЙ, СЕТЕВАЯ БЕЗОПАСНОСТЬ, АНАЛИЗ СЕТЕВОГО ТРАФИКА, ГЛУБОКОЕ ОБУЧЕНИЕ, НЕЙРОННЫЕ СЕТИ, CNN-LSTM, UNSW-NB15, CICIDS2017, КОНЕЧНО-АВТОМАТНЫЙ АГЕНТ, ДРЕЙФ РАСПРЕДЕЛЕНИЙ, ФОКАЛЬНАЯ ФУНКЦИЯ ПОТЕРЬ, ТЕМПЕРАТУРНОЕ МАСШТАБИРОВАНИЕ, PSI, MMD

Объектом исследования являются методы и технологии обнаружения аномальной активности и несанкционированных действий в корпоративных сетях на основе телеметрии сетевого трафика.

Цель работы — разработка методики обнаружения аномальной активности и несанкционированных действий в корпоративной сети на основе нейронных сетей, включающей анализ сетевого трафика, классификацию угроз и моделирование атак с помощью программного агента на основе конечного автомата, генерирующего трафик по библиотеке параметризованных шаблонов и выступающего конечной точкой воспроизводимого активного тестирования системы.

В процессе работы выполнен систематический анализ литературы по NIDS и глубокому обучению; проведена балльная оценка десяти архитектур нейронных сетей по семи критериям и десяти публично доступных датасетов NIDS по восьми критериям, опирающимся на эталонный фреймворк Gharib и соавт. (2016) и обзор Ring и соавт. (2019); реализована полная программная подсистема обработки данных, обучения 15 моделей-кандидатов в едином регистре, инференса с калибровкой порога, активного тестирования и мониторинга дрейфа; проведено шесть экспериментов с 30 запусками и 15 моделями; выполнен статистический анализ результатов через bootstrap-доверительные интервалы 95 % и парный критерий Уилкоксона.

В результате исследования сформирована методика обнаружения, включающая препроцессинг flow-данных, библиотеку из семи параметризованных шаблонов атак, конечный автомат планирования режимов норма/атака/дрейф (11 состояний) и блок drift-monitoring на основе индексов PSI, KL и MMD. Реализован программный прототип на стеке Python/PyTorch с интерфейсами FastAPI и Streamlit (порядка

4000 строк исходного кода, 11 модулей юнит-тестов, 86 проходящих тестов). На датасете UNSW-NB15 проведены шесть экспериментов (E1–E6) и cross-evaluation на CICIDS2017. По композитному критерию качества целевая архитектура CNN-LSTM лидирует по семи из десяти основных метрик: $F1=0,9735$, $PR-AUC=0,9945$, $ROC-AUC=0,9923$, $MCC=0,918$, $Recall=0,985$ на F1-max пороге; на операционном пороге под целевую частоту ложных срабатываний 0,01 модель достигает $F1=0,971$ при $FPR=0,0095$ и $Recall=0,948$. Inference-задержка CNN-LSTM на CPU составила 1,16 мс/окно, пропускная способность — 24 560 EPS, что значительно превышает требования к эксплуатационной производительности. Cross-evaluation UNSW-NB15 → CICIDS2017 показал $\Delta F_1=0,18$, что удовлетворяет требованию переносимости. Все десять нефункциональных требований к системе выполнены. Научная новизна состоит в интеграции нейросетевого детектора, конечно-автоматного агента и блока мониторинга дрейфа в единую воспроизводимую методику с прозрачной ground-truth по состояниям FSM и единым протоколом экспериментов.

Областью применения результатов являются системы обнаружения вторжений корпоративного класса, учебно-исследовательские стенды по сетевой безопасности, задачи аудита устойчивости NIDS к дрейфу распределений и вариативности атак.

Программный прототип допускает развертывание в составе подсистемы NTA-аналитики корпоративного SOC. В отчете сформированы инженерные рекомендации по интеграции с источниками NetFlow / IPFIX и калибровке порогов под целевой эксплуатационный FPR. По сравнению с лидером по F1 среди классических подходов (XGBoost, $F1=0,965$) целевая модель обеспечивает в одиннадцать раз меньшее число ложных срабатываний на типовом потоке корпоративного SOC за счет существенно более низкого FPR на операционном пороге.

Эффективность работы определяется снижением частоты ложных срабатываний детектора при сохранении полноты обнаружения за счет температурной калибровки вероятностей и порога под допустимый FPR, а также сокращением времени аналитика SOC на разбор инцидентов за счет пятиступенчатой шкалы severity и временной дедупликации алертов. Все

поставленные задачи научно-исследовательской работы выполнены в полном объеме, гипотеза подтверждена, цель достигнута, методика обнаружения сформулирована, программно реализована и экспериментально проверена.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	8
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	10
ВВЕДЕНИЕ	13
1 ТЕОРЕТИЧЕСКИЙ АНАЛИЗ МЕТОДОВ ОБНАРУЖЕНИЯ АНОМАЛИЙ И ОБОСНОВАНИЕ ТРЕБОВАНИЙ К СИСТЕМЕ	17
1.1 Корпоративная сеть как объект мониторинга	17
1.2 Классификация и принципы построения IDS	18
1.3 Методы обнаружения аномалий	18
1.4 Сравнительный анализ нейросетевых архитектур	19
1.4.1 Критерии сравнения	19
1.4.2 Краткое описание архитектур	19
1.4.3 Балльная оценка и выбор архитектуры	21
1.5 Сравнительный анализ датасетов NIDS	21
1.6 Систематизация подходов к активному тестированию NIDS ...	22
1.7 Метрики качества	23
1.8 Формализация требований и гипотеза	24
2 ПРОЕКТИРОВАНИЕ МЕТОДИКИ ОБНАРУЖЕНИЯ И АРХИТЕКТУРЫ ПРОТОТИПА	26
2.1 Общая архитектура системы	26
2.2 Подсистема предобработки и формирование входных представлений	26
2.2.1 Схема признаков UNSW-NB15	26
2.2.2 Pipeline обработки	27
2.2.3 Управление дисбалансом классов	28
2.3 Архитектура нейросетевого детектора	28
2.3.1 Целевая архитектура CNN-LSTM	28
2.3.2 Совокупность альтернативных моделей	29
2.3.3 Сценарий обучения	29
2.4 Калибровка вероятностей и порога принятия решения	30
2.5 Подсистема алертирования	31

2.6	Архитектура конечно-автоматного агента активного тестирования	31
2.6.1	Состояния и политика	31
2.6.2	Библиотека шаблонов атак	31
2.6.3	Инжектор дрейфа распределений	32
2.7	Подсистема мониторинга дрейфа	33
2.8	Протокол экспериментального исследования	33
3	ПРОГРАММНАЯ РЕАЛИЗАЦИЯ ПРОТОТИПА СИСТЕМЫ ОБНАРУЖЕНИЯ.....	35
3.1	Стек и общая структура программного проекта.....	35
3.2	Подсистема обработки данных	36
3.3	Реализованные модели	37
3.4	Подсистема обучения и оценки	38
3.5	Конечно-автоматный агент	38
3.5.1	Шаблоны атак	38
3.5.2	Конечно-автоматный планировщик	39
3.5.3	Инжектор дрейфа и runtime	39
3.6	Подсистема online-инференса и интерфейс	40
3.6.1	FastAPI-сервис	40
3.6.2	Формирование алертов	40
3.6.3	Streamlit-дэшборд.....	40
3.7	Воспроизводимость и журналирование	40
3.8	Покрывание тестами	41
3.9	Соответствие реализации функциональным требованиям	41
4	ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ РАЗРАБОТАННОЙ МЕТОДИКИ И ПОДТВЕРЖДЕНИЕ ГИПОТЕЗЫ	43
4.1	Условия экспериментов.....	43
4.1.1	Параметры разделения и препроцессинга	43
4.2	Эксперимент E1: сравнение моделей-кандидатов	44
4.2.1	Цель и условия	44
4.2.2	Результаты	44
4.2.3	Анализ E1	46
4.3	Эксперимент E2: анализ ошибок CNN-LSTM.....	47

4.4	Эксперимент E3: калибровка вероятностей и порога	49
4.5	Эксперимент E4: стресс-тест с конечно-автоматным агентом ..	49
4.5.1	Цель и условия	49
4.5.2	Результаты	50
4.6	Эксперимент E5: устойчивость к контролируемому дрейфу ...	51
4.6.1	Цель и условия	51
4.6.2	Результаты	52
4.7	Эксперимент E6: эксплуатационная производительность	53
4.8	Cross-evaluation UNSW-NB15 на CICIDS2017	54
4.9	Демонстрационный прогон	55
4.10	Обоснование выбора CNN-LSTM по композитному критерию	55
4.11	Подтверждение гипотезы исследования и соответствие требо- ваниям	57
ЗАКЛЮЧЕНИЕ		59
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ		64
ПРИЛОЖЕНИЯ		69
Приложение А (справочное). Полная таблица результатов экспери- мента E1		69
Приложение Б (справочное). Структура программного прототипа и команды запуска		71
Приложение В (справочное). Конфигурации экспериментов		72

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящем отчете о НИР применяют следующие термины с соответствующими определениями.

Алерт — сформированное системой обнаружения событие безопасности, сопровождаемое уровнем критичности, скорингом, типом предположительной атаки и контекстом наблюдения, направляемое в SOC для последующей обработки аналитиком

Аномальная сетевая активность — поведение сетевых соединений, статистически отклоняющееся от характерного для контролируемой инфраструктуры профиля нормы, проявляющееся в признаках длительности, направления, объема и последовательности соединений

Аномальный детектор — программный модуль, формирующий непрерывный скоринг $s(x): X \rightarrow \mathbb{R}$ и принимающий решение об аномальности наблюдения x при превышении порога τ

Дрейф распределений — изменение совместного распределения $p(x, y)$ или его компонент во времени в продуктивной эксплуатации; источник деградации аномального детектора

Калибровка вероятностей — процедура согласования выходной вероятности классификатора с эмпирической частотой положительного класса; в работе используется температурное масштабирование

Конечно-автоматный агент — программный компонент активного тестирования, формирующий поток сетевых событий с управляемым переключением режимов норма/атака/ дрейф на основе вероятностной матрицы переходов конечного автомата и библиотеки параметризованных шаблонов трафика

Несанкционированные действия в сети — действия, нарушающие установленную политику безопасности корпоративной информационной системы, в том числе попытки получения неавторизованного доступа, эксфильтрации данных, исчерпания ресурсов, скрытого латерального перемещения и развертывания вредоносного кода

Сетевой поток (flow) — агрегированная единица сетевого трафика, описываемая совокупностью характеристик (src/dst IP, src/dst port, protocol) в пределах заданного временного интервала и характеризующаяся длительностью, числом переданных пакетов и байтов, межпакетными интервалами и сопутствующими статистиками

Скользящее окно (sliding window) — последовательность из W подряд идущих flow-записей, используемая в качестве входа модели; параметры окна — размер W и шаг S

Шаблон атаки — параметризованное описание характеристик потока сетевых событий, соответствующих определенному классу несанкционированной активности (DDoS, port scan, brute force, exploit payload, data exfiltration, internal reconnaissance, worm lateral movement)

NIDS (Network-based Intrusion Detection System) — сетевая система обнаружения вторжений, осуществляющая анализ проходящего трафика для выявления попыток несанкционированного доступа

NTA (Network Traffic Analysis) — подкласс систем мониторинга сетевой безопасности, ориентированный на анализ метаданных сетевых соединений flow-уровня с применением статистических и машинно-обучаемых моделей

SOC (Security Operations Center) — функциональная организационно-техническая структура мониторинга и реагирования на инциденты информационной безопасности корпоративного класса

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящем отчете о НИР применяют следующие сокращения и обозначения.

АЕ — Autoencoder, автоэнкодер

АТТ&СК — Adversarial Tactics, Techniques and Common Knowledge — матрица MITRE

BiLSTM — Bidirectional Long Short-Term Memory

cGAN — Conditional Generative Adversarial Network

CI — Confidence Interval, доверительный интервал

CNN — Convolutional Neural Network, сверточная нейронная сеть

DL — Deep Learning, глубокое обучение

DPI — Deep Packet Inspection, глубокий анализ пакета

ECE — Expected Calibration Error

EDA — Exploratory Data Analysis

EPS — Events Per Second, событий в секунду

FAR — False Alarm Rate

FN — False Negative, ложноотрицательный

FP — False Positive, ложноположительный

FPR — False Positive Rate

FSM — Finite-State Machine, конечный автомат

GAN — Generative Adversarial Network

GRU — Gated Recurrent Unit

IAT — Inter-Arrival Time, межпакетный интервал

IDS — Intrusion Detection System

IPFIX — IP Flow Information Export

IPS — Intrusion Prevention System

IQR — Interquartile Range, межквартильный размах

KDD — Knowledge Discovery in Databases

KL — Kullback–Leibler divergence

KS-test — Kolmogorov–Smirnov test

LSTM — Long Short-Term Memory

MCC — Matthews Correlation Coefficient

ML — Machine Learning, машинное обучение

MLP — Multilayer Perceptron, многослойный перцептрон

MMD — Maximum Mean Discrepancy

NIDS — Network-based Intrusion Detection System

NTA — Network Traffic Analysis

OCSVM — One-Class Support Vector Machine

OOD — Out-Of-Distribution

PR-AUC — Area Under the Precision–Recall Curve

PSI — Population Stability Index

ReLU — Rectified Linear Unit

RF — Random Forest, случайный лес

RNN — Recurrent Neural Network, рекуррентная нейронная сеть

ROC-AUC — Area Under the Receiver Operating Characteristic Curve

SOAR — Security Orchestration, Automation and Response

SOC — Security Operations Center, центр мониторинга безопасности

SVM — Support Vector Machine

TCN — Temporal Convolutional Network

TN — True Negative, истинноотрицательный

TP — True Positive, истинноположительный

TPR — True Positive Rate, чувствительность (Recall)

TTD — Time-To-Detect, время до обнаружения

VAE — Variational Autoencoder, вариационный автоэнкодер

XGBoost — eXtreme Gradient Boosting

ВВЕДЕНИЕ

Актуальность работы. Корпоративные сети Российской Федерации остаются устойчивой целью несанкционированных воздействий, включающих эксфильтрацию данных, латеральное перемещение, разведку, отказ в обслуживании и эксплуатацию уязвимостей сетевых сервисов. Доля шифрованного трафика в современных корпоративных инфраструктурах превышает 90 %, что делает сигнатурный анализ полезной нагрузки малоэффективным. Центр тяжести разработки систем обнаружения вторжений (Intrusion Detection Systems, IDS) переходит в сторону аномального анализа метаданных потоков с применением методов машинного и глубокого обучения [1; 2]. При этом существенной проблемой остается воспроизводимая, формализованная оценка таких систем в условиях, приближенных к реальной эксплуатации, в том числе при дрейфе распределений и вариативности атакующих сценариев.

Регулирование сетевой безопасности корпоративных инфраструктур Российской Федерации опирается на Федеральный закон от 26.07.2017 № 187-ФЗ «О безопасности критической информационной инфраструктуры Российской Федерации», Указ Президента Российской Федерации от 01.05.2022 № 250 «О дополнительных мерах по обеспечению информационной безопасности», Доктрину информационной безопасности Российской Федерации (Указ Президента Российской Федерации от 05.12.2016 № 646), приказ ФСТЭК России от 25.12.2017 № 239 в действующей редакции, требующий внедрения средств обнаружения и предотвращения компьютерных атак (группы требований COB.1 и COB.2). Совокупность нормативных актов формирует объективный спрос на отечественные методики и программные средства NIDS, удовлетворяющие требованиям регулятора.

Объект исследования — методы и технологии обнаружения аномальной активности и несанкционированных действий в корпоративных сетях на основе телеметрии сетевого трафика. Данные о поведении пользователей рассматриваются в теоретической части как один из возможных источников, в экспериментальной реализации и валидации не используются.

Предмет исследования — применение нейросетевых методов для выявления аномалий и признаков несанкционированной активности по данным сетевого трафика, а также разработка и применение программного агента

на основе конечного автомата и библиотеки параметризованных атакующих шаблонов для синтеза трафика и сценариев активного тестирования и валидации системы обнаружения.

Цель работы. Разработка методики обнаружения аномальной активности и несанкционированных действий в корпоративной сети на основе нейронных сетей, включающей анализ сетевого трафика, классификацию угроз и моделирование атак с помощью программного агента на основе конечного автомата, генерирующего трафик по библиотеке параметризованных шаблонов и выступающего конечной точкой воспроизводимого активного тестирования системы.

Задачи исследования:

- 1) Аналитический обзор предметной области обнаружения аномалий и несанкционированных действий в корпоративных сетях; сравнительный анализ нейросетевых архитектур и публично доступных датасетов NIDS.
- 2) Формализация функциональных и нефункциональных требований к системе обнаружения и определение количественных критериев качества.
- 3) Проектирование методики и архитектуры нейросетевого детектора аномальной активности.
- 4) Разработка подсистемы предобработки и формирования обучающих и тестовых выборок.
- 5) Реализация и обучение нейросетевой модели детекции в едином программном регистре с совокупностью моделей-кандидатов.
- 6) Разработка конечно-автоматного агента активного тестирования с библиотекой шаблонов и инжектором дрейфа.
- 7) Реализация программного прототипа системы обнаружения в реальном времени с REST-интерфейсом и визуальной панелью.
- 8) Экспериментальная проверка эффективности методики и подтверждение гипотезы исследования.
- 9) Оценка эксплуатационных характеристик и оформление итоговых материалов.

Гипотеза исследования. Применение нейронных сетей, обрабатывающих последовательности агрегированных признаков сетевых потоков в

скользящих окнах, в сочетании с программным агентом на основе конечного автомата, формирующего воспроизводимые сценарии нормального и атакующего поведения по библиотеке параметризованных шаблонов с контролируемым инжектированием дрейфа распределений, обеспечивает построение методики обнаружения аномальной активности и несанкционированных действий в корпоративной сети, превосходящей классические сигнатурные и статистические подходы по комплексному критерию качества, включающему точность и полноту классификации, частоту ложных срабатываний при заданной полноте, задержку детекции и устойчивость к контролируемому дрейфу распределений.

Методы исследования. Систематический анализ литературы; математическое моделирование (вероятностные и информационно-теоретические меры дрейфа, формальные определения функций потерь и метрик); сравнительный анализ нейросетевых архитектур и публично доступных датасетов NIDS по балльной шкале с явно сформулированными критериями и весами; обучение нейронных сетей и классических моделей в равных условиях; статистический анализ результатов через bootstrap-доверительные интервалы и парный критерий Уилкоксона.

Научная новизна. Новизна состоит в комбинации трех компонент: (а) интеграции нейросетевого детектора аномальной активности по потоковому трафику, конечно-автоматного агента с библиотекой параметризованных шаблонов и блока мониторинга дрейфа в единую воспроизводимую методику; (б) использования прозрачной ground-truth по состояниям конечного автомата, обеспечивающей измерение характеристик детектора, недоступных при использовании только статических датасетов (per-state recall); (в) единого протокола экспериментов, включающего сравнение моделей в равных условиях, анализ ошибок, калибровку порога под эксплуатационный FPR, стресс-тестирование с агентом, drift-устойчивость и эксплуатационную производительность.

Практическая значимость. Разработанный прототип реализован на стеке Python/PyTorch с REST-интерфейсом на FastAPI и визуальной панелью на Streamlit и может быть интегрирован в подсистему сетевой аналитики корпоративного SOC. Зафиксированы рекомендации по интеграции с источниками NetFlow/IPFIX, калибровке порогов под допустимый FPR и оценке

устойчивости к дрейфу. По сравнению с лидером по F1 среди классических подходов (XGBoost) целевая модель обеспечивает в одиннадцать раз меньшее число ложных срабатываний на типовом потоке корпоративного SOC за счет существенно более низкого FPR на операционном пороге.

Структура отчета. Основная часть отчета состоит из четырех разделов, соответствующих четырем этапам, заявленным в постановке задачи. Этап 1 содержит теоретический анализ методов обнаружения аномалий, сравнительный анализ нейросетевых архитектур и публично доступных датасетов NIDS, обзор методов активного тестирования, формализацию требований и гипотезы. Этап 2 — проектирование подсистемы предобработки, архитектуры детектора, схемы калибровки порога, формирования алертов, архитектуры конечно-автоматного агента и инжектора дрейфа, а также формирование протокола экспериментов. Этап 3 — программная реализация прототипа системы обнаружения, обучение и оптимизация моделей, разработка конечно-автоматного агента. Этап 4 — комплексное тестирование прототипа, анализ эффективности, cross-evaluation, оценка эксплуатационных характеристик и формирование итоговых материалов; именно этому этапу уделено наибольшее внимание (расчет метрик, анализ ошибок, тесты с конечно-автоматным агентом, оценка устойчивости к дрейфу и производительности).

1 ТЕОРЕТИЧЕСКИЙ АНАЛИЗ МЕТОДОВ ОБНАРУЖЕНИЯ АНОМАЛИЙ И ОБОСНОВАНИЕ ТРЕБОВАНИЙ К СИСТЕМЕ

Содержание главы соответствует первому этапу постановки задачи: изучение литературы и существующих методов обнаружения аномалий в сетевом трафике; сравнительный анализ нейросетевых архитектур и публично доступных датасетов NIDS на основе балльной оценки с явно сформулированными критериями и весами; систематизация подходов к активному тестированию NIDS; формулировка гипотезы исследования и требований к системе.

1.1 Корпоративная сеть как объект мониторинга

Под корпоративной сетью в настоящей работе понимается совокупность взаимосвязанных программно-аппаратных средств, обеспечивающих обмен данными между рабочими станциями, серверами, сетевым оборудованием и внешними сегментами. С точки зрения мониторинга безопасности корпоративная сеть характеризуется тремя свойствами, существенными для построения NIDS:

- 1) высокой неоднородностью трафика, приводящей к мультимодальному распределению признаков и затрудняющей применение единых пороговых правил [1; 2];
- 2) доминированием легитимного трафика, что создает сильный дисбаланс классов и требует специализированных методов обучения и оценки [3—5];
- 3) динамичностью характеристик, приводящей к явлению дрейфа распределений [6; 7].

Объектами мониторинга в работе принимаются: сетевые соединения (flow) на уровне L3/L4, сессии прикладного уровня и временные последовательности соединений в скользящих окнах. Это согласуется с подходом, принятым в большинстве современных систем сетевого анализа трафика и в открытых датасетах [8; 9].

В качестве рабочей таксономии угроз использована классификация датасета UNSW-NB15, выделяющая девять семейств атакующего трафика: Fuzzers, Analysis, Backdoors, DoS, Exploits, Generic, Reconnaissance, Shellcode, Worms [8].

1.2 Классификация и принципы построения IDS

В соответствии с устоявшейся в литературе типологией IDS делятся на три класса [1; 2; 10]: сигнатурные (совпадение с заранее заданным шаблоном), аномальные (отклонение от модели нормы) и гибридные. Сигнатурный класс обеспечивает высокую точность по известным угрозам, но не способен обнаруживать ранее не встречавшиеся атаки. Аномальный класс расширяет покрытие на неизвестные сценарии за счет повышенной частоты ложных срабатываний и чувствительности к дрейфу.

С точки зрения исходного представления данных различают packet-based (анализ полезной нагрузки, DPI) и flow-based анализ. Стандартами экспорта flow-записей являются Cisco NetFlow [11] и IETF IPFIX [12]. В настоящей работе принят flow-based подход по причине его совместимости с шифрованным трафиком, ресурсной эффективности и прямой переносимости на инфраструктуры реальных корпоративных сетей.

1.3 Методы обнаружения аномалий

Постановка задачи: для пространства признаков $X \subseteq \mathbb{R}^d$ требуется построить функцию скоринга $s: X \rightarrow \mathbb{R}$ и порог τ такие, что

$$\hat{y}(x) = \mathbb{I}[s(x) > \tau], \quad x \in X, \quad (1.1)$$

где $\hat{y}(x)$ — предсказанная метка наблюдения, $\hat{y}(x) = 1$ интерпретируется как «аномалия/атака»; $s(x)$ — функция скоринга наблюдения; τ — порог принятия решения; $\mathbb{I}[\cdot]$ — индикаторная функция события.

Статистические и энтропийные методы. Простейший подход — многомерное расстояние Махаланобиса:

$$d_M(x) = \sqrt{(x - \mu)^\top \Sigma^{-1} (x - \mu)}, \quad (1.2)$$

где μ — вектор математических ожиданий по обучающей выборке; Σ — ковариационная матрица обучающей выборки.

Isolation Forest [13] определяет скоринг через ожидаемую глубину

ИЗОЛЯЦИИ ТОЧКИ:

$$s(x, n) = 2^{-\frac{\mathbb{E}[h(x)]}{c(n)}}, \quad c(n) \approx 2(\ln(n-1) + 0.5772) - \frac{2(n-1)}{n}, \quad (1.3)$$

где n — размер обучающей выборки; $h(x)$ — глубина изоляции наблюдения в случайном дереве; $c(n)$ — нормирующий множитель. Метод имеет линейную сложность и подходит для unsupervised-режима.

One-Class SVM [14] ищет в спрямляющем пространстве минимальную гиперсферу, содержащую долю $1 - \nu$ обучающих наблюдений; параметр $\nu \in (0, 1]$ задает верхнюю оценку доли выбросов.

1.4 Сравнительный анализ нейросетевых архитектур

1.4.1 Критерии сравнения

Критерии сравнения нейросетевых архитектур извлечены из систематических обзоров и привязаны к проверяемым источникам. Приняты семь критериев C1–C7 [1; 2; 10; 15]: C1 — моделирование локальных паттернов; C2 — моделирование временных зависимостей; C3 — F1/Accuracy в рецензируемых работах на современных датасетах NIDS; C4 — сложность обучения; C5 — inference latency на CPU; C6 — зрелость подхода в NIDS (число независимых воспроизведений); C7 — гибкость расширения (embedding, fine-tune, online).

1.4.2 Краткое описание архитектур

В работе рассмотрено девять типов нейросетевых архитектур.

MLP реализуется рекурсией $h^{(l)} = \phi(W^{(l)}h^{(l-1)} + b^{(l)})$ и служит нижней границей DL-моделей.

1D-CNN применяет операцию свертки $(h * w)_t = \sum_{k=0}^{K-1} w_k h_{t-k}$ для извлечения локальных паттернов в скользящем окне.

LSTM [16] вводит ячейку состояния c_t и три гейта:

$$\begin{aligned}
i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i), \\
f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), \\
o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), \\
\tilde{c}_t &= \tanh(W_c[h_{t-1}, x_t] + b_c), \\
c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \\
h_t &= o_t \odot \tanh(c_t),
\end{aligned} \tag{1.4}$$

где x_t — входной вектор на шаге t ; h_{t-1} — скрытое состояние на предыдущем шаге; i_t, f_t, o_t — гейты входа, забывания и выхода; σ — сигмоидальная функция активации; $\odot$ — поэлементное произведение.

GRU [17] — упрощенная RNN с двумя гейтами; BiLSTM использует прямой и обратный LSTM для двунаправленного контекста.

Гибрид CNN-LSTM применяет последовательное преобразование

$$x_t \xrightarrow{\text{Conv1D}} z_t \xrightarrow{\text{LSTM}} h_t \xrightarrow{\text{FC}} \hat{p}_t,$$

сочетая локальные паттерны и временные зависимости.

TCN [18] использует причинные дилатированные свертки с экспоненциально растущим рецептивным полем.

Transformer-encoder [19] основан на само-внимании:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V, \tag{1.5}$$

где Q — матрица запросов; K — матрица ключей; V — матрица значений; d_k — размерность векторов ключей.

Autoencoder и VAE. Автоэнкодер минимизирует ошибку реконструкции $\|x - D(E(x))\|^2$; вариационный автоэнкодер [20] обучает вероятностное кодирование максимизацией ELBO:

$$\mathcal{L}_{\text{VAE}} = \mathbb{E}_{q(z|x)}[\log p(x|z)] - \text{KL}(q(z|x) \| p(z)), \tag{1.6}$$

где x — входное наблюдение; z — скрытая (латентная) переменная; $q(z|x)$ — кодировщик; $p(x|z)$ — декодировщик; $p(z)$ — априорное распределение

латентной переменной; KL — расхождение Кульбака–Лейблера.

1.4.3 Балльная оценка и выбор архитектуры

В таблице 1.1 приведена взвешенная балльная оценка девяти архитектур по семи критериям. Веса критериев установлены на основе их значимости для задачи классификации последовательностей flow-окон в реальном времени с эксплуатационными ограничениями SOC: C1 — 0,15; C2 — 0,20; C3 — 0,25; C4 — 0,05; C5 — 0,15; C6 — 0,10; C7 — 0,10.

Таблица 1.1 — Балльная оценка нейросетевых архитектур по критериям C1–C7

Архитектура	C1	C2	C3	C4	C5	C6	C7	Балл
MLP	1	1	2	5	5	2	2	2,15
1D-CNN	4	2	3	4	5	3	3	3,30
LSTM	1	4	3	3	4	4	3	3,15
GRU	1	4	3	4	4	4	3	3,20
BiLSTM	2	5	4	2	3	4	3	3,55
TCN	4	4	3	3	3	3	3	3,40
CNN-LSTM	5	5	5	2	4	5	5	4,60
Transformer- encoder	3	4	4	2	3	3	4	3,45
AE / VAE	2	1	2	3	4	3	3	2,40

Шкала: 1 — не соответствует; 5 — выражено соответствует.

Лидер по взвешенной балльной оценке — гибридный CNN-LSTM с баллом 4,60, опережающий ближайших конкурентов BiLSTM (3,55), Transformer-encoder (3,45) и TCN (3,40). Это решение согласуется с серией публикаций по NIDS на UNSW-NB15 в 2024–2025 годах, в которых CNN-LSTM устойчиво обеспечивает наибольшие F1 и Accuracy в DL-семействе [2; 10; 15].

1.5 Сравнительный анализ датасетов NIDS

Критерии оценки датасетов NIDS опираются на эталонный фреймворк Gharib и соавт. (2016) [21] и обзор Ring и соавт. (2019). Приняты восемь критериев K1–K8: K1 — актуальность модели угроз; K2 — репрезентативность нормального трафика; K3 — качество разметки; K4 — сбалансированность распределения классов; K5 — пригодность для глубокого обучения; K6 —

flow-формат и совместимость с NetFlow/IPFIX; K7 — воспроизводимость (открытая лицензия, документация); K8 — активность использования в современной литературе.

В таблице 1.2 приведена 5-балльная оценка десяти публично доступных датасетов NIDS по критериям K1–K8.

Таблица 1.2 — Балльная оценка публично доступных датасетов NIDS

Датасет	K1	K2	K3	K4	K5	K6	K7	K8
DARPA 1998/1999 [22]	1	2	3	3	1	2	4	1
KDDCup99 [23]	1	1	2	3	3	2	4	2
NSL-KDD [23]	1	2	3	4	2	2	5	4
UNSW-NB15 [8]	5	5	5	4	5	5	5	5
CICIDS2017 [9]	4	4	2	3	4	5	4	5
CSE-CIC-IDS2018	4	4	2	3	4	5	3	4
TON-IoT [24]	4	3	4	3	4	5	4	4
Bot-IoT [25]	3	1	4	1	4	5	4	3
Kyoto 2006+ [26]	2	2	3	3	3	3	3	2
LITNET-2020 [27]	4	4	3	3	4	4	3	3

Веса критериев согласованы с приоритетами Gharib и соавт. (2016) и обзорной работы Ring и соавт. (2019): K1, K2, K3, K5 — по 0,15; K4, K6, K7, K8 — по 0,10. Взвешенный балл лидеров: UNSW-NB15 — 4,80; TON-IoT — 3,80; CICIDS2017 — 3,75.

В работе принят UNSW-NB15 как основной датасет, CICIDS2017 — как вспомогательный для cross-evaluation в проверке гипотезы переносимости методики.

1.6 Систематизация подходов к активному тестированию NIDS

В литературе устойчиво выделяются три семейства подходов к формированию атакующего трафика для тестирования NIDS:

- 1) Шаблонная (rule/template-based) генерация: атаки задаются параметрическими шаблонами потоков; применение — от классических работ DARPA/KDD [21; 22] до открытых инструментариев типа ID2T и ConCap.

- 2) Генеративные модели: GAN, cGAN, WGAN, VAE для синтеза реалистичных flow-векторов и последовательностей [28—33].
- 3) Adversarial-агенты на обучении с подкреплением: агент обучается формировать последовательности действий, обходящих детектор [34].

В рамках настоящей работы выбран гибридный шаблонный подход с конечно-автоматным планировщиком и инжектором дрейфа:

Templates + FSM-планировщик + Drift-инжектор.

Аргументы выбора: высокая воспроизводимость и прозрачная ground-truth; семантическая согласованность шаблонов с таксономией UNSW-NB15; отсутствие риска коллапса режима, характерного для GAN-семейства; интерпретируемость для аналитика SOC.

1.7 Метрики качества

Для бинарной задачи введены матрица ошибок (TP, TN, FP, FN) и производные метрики:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad (1.7)$$

$$F1 = \frac{2 \text{Precision Recall}}{\text{Precision} + \text{Recall}}, \quad \text{FPR} = \frac{FP}{FP + TN}. \quad (1.8)$$

MCC (Matthews correlation coefficient) рекомендуется при сильном дисбалансе:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}. \quad (1.9)$$

ROC-AUC и PR-AUC интегрируют качество модели по всем порогам; PR-AUC более чувствителен к редкому классу и принят как основная интегральная метрика. К эксплуатационным метрикам относятся time-to-detect (TTD), inference latency, throughput и FP-per-time.

Температурное масштабирование [35] согласует выходную вероятность с эмпирической частотой:

$$\hat{p}_T(y = 1 \mid x) = \sigma\left(\frac{z(x)}{T}\right), \quad (1.10)$$

где $z(x)$ — логит, T — параметр, подбираемый на валидационной выборке. Качество калибровки оценивается по ECE (Expected Calibration Error).

Метрики дрейфа. Population Stability Index, расхождение Кульбака–Лейблера и Maximum Mean Discrepancy:

$$\text{PSI} = \sum_b (p_b - q_b) \ln \frac{p_b}{q_b}, \quad (1.11)$$

$$\text{MMD}^2(P, Q) = \mathbb{E}_{P,P}[k(x, x')] - 2\mathbb{E}_{P,Q}[k(x, y)] + \mathbb{E}_{Q,Q}[k(y, y')], \quad (1.12)$$

где b — индекс интервала разбиения признакового пространства; p_b и q_b — доли наблюдений в b -м интервале эталонной и текущей выборки соответственно; $k(\cdot, \cdot)$ — характеристическое ядро (гауссово ядро с автобандвидтом по медианной эвристике).

1.8 Формализация требований и гипотеза

Концептуальная модель системы состоит из трех подсистем: предобработки, детекции и активного тестирования (конечно-автоматный агент). Сформированы 10 функциональных и 10 нефункциональных требований; ключевые количественные пороги приведены в таблице 1.3.

Таблица 1.3 — Ключевые нефункциональные требования к системе

ID	Содержание	Порог
NFR-1a	F1 на UNSW-NB15 (binary)	$\geq 0,90$
NFR-1b	PR-AUC на UNSW-NB15	$\geq 0,95$
NFR-2	FPR при Recall $\geq 0,85$	$\leq 0,01$
NFR-3	Inference latency (CPU, batch=1)	≤ 50 мс/окно
NFR-4	Throughput (CPU, батч)	≥ 1000 EPS
NFR-5	Time-to-detect (DDoS / Scan / Brute)	≤ 1 окна
NFR-6	$\Delta F1$ при PSI $\leq 0,25$	$\leq 0,10$
NFR-7	Перенос UNSW $\rightarrow$ CICIDS2017 ($\Delta F1$)	$\leq 0,20$
NFR-8	Воспроизводимость одной командой	да
NFR-9	σ_{F1} при $n \geq 3$ seed	$\leq 0,01$

Формально сформулирована гипотеза исследования: применение ней-

ронных сетей, обрабатывающих последовательности агрегированных признаков сетевых потоков в скользящих окнах, в сочетании с программным агентом на основе конечного автомата с библиотекой параметризованных шаблонов и контролируемым инжектированием дрейфа распределений, обеспечивает построение методики обнаружения, превосходящей классические сигнатурные и статистические подходы по комплексному критерию качества (точность, полнота, FPR при заданной полноте, задержка детекции, устойчивость к дрейфу). Проверка проводится на этапе 4.

Выводы по главе 1

- 1) Корпоративная сеть как объект мониторинга характеризуется неоднородностью трафика, дисбалансом классов и динамичностью распределений; обоснован выбор flow-уровня анализа, совместимого с NetFlow/IPFIX.
- 2) Сигнатурные, аномальные и гибридные подходы NIDS дополняют, а не заменяют друг друга; в работе принят аномальный нейросетевой подход.
- 3) Рассмотрены девять типов нейросетевых архитектур; по результатам взвешенной балльной оценки лидер — гибрид CNN-LSTM с баллом 4,60, принимаемый в качестве основной proposed-архитектуры.
- 4) Из десяти публично доступных датасетов NIDS лидером по взвешенной балльной оценке является UNSW-NB15 (балл 4,80); как вспомогательный принят CICIDS2017.
- 5) Систематизированы три семейства подходов к моделированию атак; обоснован выбор гибридного шаблонного подхода с конечно-автоматным планировщиком без cGAN-составляющей.
- 6) Сформированы количественные требования (10 функциональных, 10 нефункциональных) и гипотеза исследования.

2 ПРОЕКТИРОВАНИЕ МЕТОДИКИ ОБНАРУЖЕНИЯ И АРХИТЕКТУРЫ ПРОТОТИПА

Содержание главы соответствует второму этапу постановки задачи: проектирование подсистемы предобработки сетевых потоков и схемы входных представлений модели, архитектуры нейросетевого детектора со схемой калибровки порога и формирования алертов, архитектуры конечно-автоматного агента с библиотекой параметризованных шаблонов трафика и инжектором дрейфа распределений, а также формирование протокола экспериментального исследования с количественными критериями принятия.

2.1 Общая архитектура системы

Система проектируется в виде четырех подсистем:

- 1) Подсистема предобработки — валидация схемы потоковых данных, нормализация, кодирование, формирование скользящих окон.
- 2) Подсистема детекции — нейросетевая модель, формирующая вероятность атаки для каждого окна; калибровка порога.
- 3) Подсистема активного тестирования — программный агент на основе конечного автомата с библиотекой шаблонов и инжектором дрейфа.
- 4) Подсистема алертирования и мониторинга — формирование алертов с уровнями критичности, мониторинг дрейфа распределений, дедупликация, экспорт в SOC.

Принципы проектирования: декларативная YAML-конфигурируемость каждой подсистемы; единый формат представления потокового признака FlowRecord; слабая связность модулей; совместимость с RFC 3954 NetFlow v9 [11] и RFC 7011 IPFIX [12].

2.2 Подсистема предобработки и формирование входных представлений

2.2.1 Схема признаков UNSW-NB15

Датасет UNSW-NB15 содержит 44 содержательных признака, разделяемых на пять групп (таблица 2.1) [8; 36].

Таблица 2.1 — Группы признаков UNSW-NB15 и их назначение

Группа	Состав и роль в детекции
Базовые потоковые	dur, proto, service, state, sbytes, dbytes, sttl, dttl, sloss, dloss, rate; длительность, протокол, состояние сессии, байты в обе стороны, общая скорость потока
Контентные	sload, dload, swin, dwin, smean, dmean, stcpb, dtcpb, trans_depth, response_body_len, spkts, dpkts; скорости, окна TCP, базовые транзакционные характеристики
Временные	sjit, djit, sinpkt, dinpkt, tcprtt, synack, ackdat; межпакетные интервалы, джиттеры, RTT, timing-сигнатуры
Дополнительные флаги	ct_state_ttl, ct_flw_http_mthd, is_ftp_login, ct_ftp_cmd, is_sm_ips_ports; агрегаты по протокольному поведению, бинарные флаги
Контекстные ct_*	ct_srv_src, ct_srv_dst, ct_dst_ltm, ct_src_ltm, ct_src_dport_ltm, ct_dst_sport_ltm, ct_dst_src_ltm; агрегаты по последним 100 соединениям; отражают сканирование и фан-аут

2.2.2 Pipeline обработки

Полный pipeline принимает на вход поток flow-записей:

IPFIX/CSV → Schema → Cleanup → Encoding
→ Scaling → Windowing → Model
→ Threshold → Alert

Очистка. Применяются: замена нечисловых пропусков константой, числовых — нулем; унификация регистра и пробелов в полях `service`, `state`, `proto`; удаление дубликатов; обрезка крайних 0,1 % хвостов распределений на основе квантилей 0,001 и 0,999. Вся статистика собирается только на обучающей выборке, что исключает test-time leakage по построению.

Кодирование категориальных признаков. One-hot для признаков с малой кардинальностью (`proto`, `state`); frequency-encoding для `service`:

$$e_{\text{freq}}(c) = \frac{|\{i : x_i^{(c)} = c\}|}{n_{\text{train}}}, \quad (2.1)$$

где c — значение категориального признака; n_{train} — размер обучающей выборки.

Преобразование числовых признаков. Лог-преобразование тяжелохвостых признаков $\tilde{x} = \log(1 + x)$ с последующим robust-scaling:

$$\tilde{x}' = \frac{\tilde{x} - \text{med}(\tilde{x})}{\text{IQR}(\tilde{x})}, \quad (2.2)$$

где med — медиана признака по обучающей выборке; IQR — межквартильный размах. Робастные оценки устойчивы к выбросам — критично для NIDS, где аномалии формируют хвосты распределения.

Скользящие окна. Принят размер $W = 32$ с шагом $S = 8$ (75 % перекрытие). Метка окна формируется по последнему flow (last-агрегация) с учетом эмпирически обоснованной структуры UNSW-NB15.

2.2.3 Управление дисбалансом классов

Применяется focal loss [5]:

$$\mathcal{L}_{\text{focal}} = -\frac{1}{n} \sum_{i=1}^n \alpha_{y_i} (1 - p_{y_i})^{\gamma} \log p_{y_i}, \quad (2.3)$$

где p_{y_i} — предсказанная вероятность истинного класса для i -го объекта; α_{y_i} — весовой коэффициент класса ($\alpha = 0,25$ для положительного класса); γ — параметр фокусирования ($\gamma = 2,0$). Для классических baselines дополнительно применяется class re-weighting $w_c = n/(|C| n_c)$.

2.3 Архитектура нейросетевого детектора

2.3.1 Целевая архитектура CNN-LSTM

По результатам балльной оценки этапа 1 в качестве целевой архитектуры принят гибрид CNN-LSTM. Детальная схема:

$$\begin{aligned} \text{Input}(B, W, F) &\rightarrow \underbrace{[\text{Conv1D} \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{MaxPool} \rightarrow \text{Dropout}] \times 2}_{\text{два сверточных блока}} \\ &\rightarrow \text{BiLSTM} \rightarrow \text{Attention Pool} \rightarrow \text{LayerNorm} \rightarrow \text{MLP-head} \rightarrow \text{Si} \end{aligned}$$

Усиления относительно базовой схемы CNN-LSTM: двунаправленный LSTM по умолчанию (стандартная практика NIDS-публикаций 2024–2025 [2; 15]); attention-пулинг над выходами LSTM вместо последнего скрытого со-

стояния, стабилизирующий обучение по seed; LayerNorm перед head, снимающий scale drift между Conv и LSTM активациями.

2.3.2 Совокупность альтернативных моделей

Для эксперимента в равных условиях реализуются 15 моделей-кандидатов в едином программном регистре. Состав регистра приведен в таблице 2.2.

Таблица 2.2 — Совокупность моделей-кандидатов в едином регистре

Имя	Тип	Назначение
mlp	DL supervised	нижняя граница DL-семейства
cnn1d	DL supervised	базовая сверточная сеть
cnn_lstm	DL supervised, proposed	целевая архитектура
lstm	DL supervised	рекуррентный baseline
gru	DL supervised	облегченная RNN
bilstm	DL supervised, attn	двунаправленный контекст
tcn	DL supervised	темпоральные дилатир. свертки
transformer	DL supervised	self-attention encoder
autoencoder	DL semi-supervised	semi-supervised режим
vae	DL semi-supervised	вариационный AE
logistic_regression	classical	линейный baseline
random_forest	classical	ансамблевый baseline
xgboost	classical	gradient boosting baseline
isolation_forest	classical unsup.	unsupervised
ocsvm	classical one-class	one-class режим

2.3.3 Сценарий обучения

Гиперпараметры обучения зафиксированы в таблице 2.3.

Таблица 2.3 — Гиперпараметры обучения DL-моделей

Параметр	Значение	Назначение
Оптимизатор	AdamW	адаптивный градиентный метод
Learning rate	$1,0 \cdot 10^{-3}$	базовая скорость обучения
Weight decay	$1,0 \cdot 10^{-4}$	регуляризация
Batch size	256	размер минибатча
Эпохи (макс.)	30 (60 для CNN-LSTM)	лимит обучения
Patience	7 (12 для CNN-LSTM)	окно early stopping
Метрика мониторинга	val_pr_auc	метрика остановки
LR-scheduler	cosine annealing	снижение lr к 10^{-6}
Gradient clipping	$\ g\ _2 \leq 1,0$	защита от взрыва градиентов
Loss-функция	focal loss	противодействие дисбалансу
α (focal)	0,25	вес положительного класса
γ (focal)	2,0	фокусировка на трудных примерах
Seed	42, 123, 2024	3 запуска для proposed

2.4 Калибровка вероятностей и порога принятия решения

Применяется однопараметрическое температурное масштабирование [35] логитов на валидационной выборке через L-BFGS, минимизирующее negative log-likelihood. Затем выполняется поиск порога τ^* под целевую частоту ложных срабатываний $FPR^* = 0,01$ бинарным поиском по отсортированному списку скорингов нормальных окон. Качество калибровки оценивается по Expected Calibration Error с 15 биннами равной ширины.

2.5 Подсистема алертирования

Принимается пятиступенчатая шкала severity, согласованная с типовыми классификациями SIEM:

Таблица 2.4 — Шкала уровней критичности алертов

Уровень	Условие s/τ	Действие SOC
info	$[1,0; 1,1)$	информационное событие
low	$[1,1; 1,3)$	стандартный обзор L1
medium	$[1,3; 1,6)$	приоритетный обзор, передача L2
high	$[1,6; 2,0)$	передача L2, расследование
critical	$\geq 2,0$	немедленное расследование

Дополнительно реализуется временная дедупликация алертов с $\Delta t_{\text{dedup}} = 5$ с по триплету (src_ip, dst_ip, attack_cat) для подавления шумовых повторов одного инцидента.

2.6 Архитектура конечно-автоматного агента активного тестирования

2.6.1 Состояния и политика

Принимается 11 состояний конечного автомата:

$$\mathcal{S} = \{\text{NORMAL}\} \cup \{\text{ATTACK}(c)\}_{c \in \mathcal{C}} \cup \{\text{DRIFT}(k)\}_{k \in \mathcal{K}},$$

где $\mathcal{C} = \{\text{DDoS}, \text{Scan}, \text{Brute}, \text{Exploit}, \text{Exfil}, \text{IntRec}, \text{Worm}\}$, $\mathcal{K} = \{\text{covariate}, \text{prior}, \text{concept}\}$. Политика $\pi : \mathcal{S} \rightarrow \Delta(\mathcal{S})$ задается стохастической матрицей вероятностей переходов в YAML-конфигурации с минимальными длительностями состояний.

2.6.2 Библиотека шаблонов атак

Реализуются семь параметризованных шаблонов атак плюс шаблон normal (таблица 2.5).

Таблица 2.5 — Реализованная библиотека шаблонов атак

Шаблон	Параметризация	Класс UNSW
ddos_ synflood	интенсивность λ_0 , длительность, доля SYN, распределение исходных IP	DoS
port_ scan	скорость подключений ρ , диапазон портов, режим, длительность	Reconnaissance
brute_ force	интервал между попытками, целевой порт, доля успехов	Reconnaissance / Exploits
exploit_ payload	размер payload, сочетания TCP-флагов, доля retransmissions	Exploits
data_ exfil	длительность сессии, асимметрия b_{out}/b_{in} , стабильность скорости	Backdoors
internal_ recon	фан-аут потоков, периодичность, размер сессии	Reconnaissance
worm_ lateral	число направленных потоков, периодичность, размер сессии	Worms

Шаблоны реализуются в двух режимах: эмпирическом (фитятся на выборке UNSW-NB15-train, sampling из эмпирических распределений по attack_cat) и параметрическом (вручную параметризованные диапазоны, fallback). Эмпирический режим обеспечивает близость к маргинальным распределениям источника и используется в production-режиме.

2.6.3 Инжектор дрейфа распределений

Реализуются три типа дрейфа согласно типологии Gama и соавт. [6].

Covariate drift. Изменение $P(X)$ при фиксированном $P(Y | X)$:

$$x'_i = (1 + \alpha \cdot u_i) \cdot x_i + \alpha \cdot \sigma_i \cdot \varepsilon_i,$$

где $u_i \sim \mathcal{U}(-0,5; 0,5)$, $\varepsilon_i \sim \mathcal{N}(0, 1)$, σ_i — стандартное отклонение признака на train, α — интенсивность дрейфа.

Prior drift. Изменение $P(Y)$ при сохранении $P(X | Y)$ через изменение долей классов в политике FSM.

Concept drift. Изменение $P(Y | X)$ через маскирование сигнатурных признаков атак (зануление или подмена характерных значений state, ct_*-

агрегатов).

Контроль интенсивности — параметр $\alpha \in \{0; 0,25; 0,5; 0,75; 1,0\}$.

2.7 Подсистема мониторинга дрейфа

Реализуются три индекса, взаимно дополняющих друг друга. PSI — по маржинальным распределениям, с устоявшимся в практике порогом $\text{PSI} > 0,25$; KL-расхождение по биннам; MMD^2 с гауссовым ядром и автобандвид-том по медианной эвристике. Подсистема возвращает агрегированный отчет `drift_report` с индикатором `drift_alarm`.

2.8 Протокол экспериментального исследования

Сформирован протокол шести экспериментов (таблица 2.6) плюс cross-evaluation и демонстрационный прогон в реальном времени.

Таблица 2.6 — Протокол экспериментального исследования

ID	Цель	Метрики	Критерий принятия
E1	Сравнение 15 моделей в равных условиях на UNSW-NB15	Precision, Recall, F1, MCC, PR-AUC, ROC-AUC, σ_{F1}	$F1 \geq 0,90$; $\text{PR-AUC} \geq 0,95$; $p < 0,05$ vs ансамбль baselines
E2	Анализ ошибок CNN-LSTM по <code>attack_cat</code>	confusion matrix, per-class recall	идентификация классов с пониженной полнотой
E3	Калибровка порога; температурное масштабирование	ECE до/после, T^* , τ^* , FPR на test	$\Delta\text{ECE} \geq 30\%$ для CNN-LSTM
E4	Стресс-тест с FSM-агентом, per-state recall	F1, Precision, Recall, per-state recall, FPR	per-state recall $\geq 0,50$ для ≥ 5 классов
E5	Drift-устойчивость; PSI/MMD-инжектирование	F1, PR-AUC vs α ; PSI, MMD; <code>drift_alarm</code>	$\Delta F1 \leq 0,10$ при $\text{PSI} \leq 0,25$; <code>drift_alarm</code> срабатывает при $\text{PSI} > 0,25$
E6	Эксплуатационная производительность	inference latency, throughput, CPU/RAM	NFR-3 (≤ 50 мс), NFR-4 (≥ 1000 EPS)

Для каждого эксперимента применяются: множественные seed ($n \geq 3$ для лидирующих моделей), bootstrap CI 95 %, парный критерий Уилкоксона при сравнении пар моделей, фиксированные YAML-конфиги.

Выводы по главе 2

- 1) Спроектирована четырехподсистемная архитектура с декларативной YAML-конфигурируемостью и совместимостью с NetFlow v9 / IPFIX.
- 2) Описана теоретическая модель данных и pipeline обработки UNSW-NB15: схема признаков, очистка, encoding, log-преобразование, robust-scaling, скользящие окна $W = 32$, $S = 8$, last-агрегация меток, focal loss для управления дисбалансом классов.
- 3) Зафиксирована детальная схема целевой архитектуры CNN-LSTM с двунаправленным LSTM, attention-пулингом и LayerNorm; реализован регистр из 15 моделей-кандидатов.
- 4) Спроектирована двухступенчатая калибровка: температурное масштабирование + поиск порога под target-FPR; пятиступенчатая шкала severity и временная дедупликация.
- 5) Сформирована архитектура конечно-автоматного агента с 11 состояниями, 7 шаблонами атак, инжектором дрейфа трех типов в эмпирическом и параметрическом режимах.
- 6) Сформирован протокол шести экспериментов E1–E6 с количественными критериями принятия.

3 ПРОГРАММНАЯ РЕАЛИЗАЦИЯ ПРОТОТИПА СИСТЕМЫ ОБНАРУЖЕНИЯ

Содержание главы соответствует третьему этапу постановки задачи: разработка программного прототипа системы обнаружения аномалий (проектирование архитектуры, реализация модулей предобработки и формирования окон, ядра детекции, минимального интерфейса), обучение и оптимизация моделей с подготовкой реальных данных, разработка конечно-автоматного агента и библиотеки атакующих сценариев.

3.1 Стек и общая структура программного проекта

Прототип реализован на платформе Windows 11 в среде Visual Studio Code в виде Python-пакета `diploma_nids`. Технологический стек выбран по результатам сравнительного анализа в открытых публикациях.

- Python 3.10+ (тестировался на 3.13.11) — основной язык.
- PyTorch 2.x (CPU-сборка) — глубокое обучение; выбран по зрелости детерминированных CPU-ядер и доминирующему положению в публикациях NIDS 2024–2025.
- scikit-learn 1.x — классические baseline-модели.
- XGBoost — gradient boosting baseline [37].
- Pydantic v2 — валидация конфигов и схем данных.
- PyYAML — параметризация всех стадий pipeline.
- FastAPI + uvicorn — REST API инференса.
- Streamlit — визуальная панель мониторинга.
- pytest — юнит-тестирование (11 модулей).
- Make — оркестрация сборки и воспроизводимости.

Общая структура проекта приведена в таблице 3.1. Общий объем исходного кода — порядка 4000 строк Python.

Таблица 3.1 — Структура программного проекта `diploma_nids`

Каталог	Назначение	Ключевые модули
<code>configs/</code>	21 YAML-файл для всех стадий	<code>data</code> , <code>preprocess</code> , <code>models</code> , <code>train</code> , <code>eval</code> , <code>attacker</code> , <code>pipeline</code>
<code>data/</code>	Схемы, загрузка, препроцессинг, окна, <code>splits</code>	<code>schema.py</code> , <code>load.py</code> , <code>preprocess.py</code> , <code>windowing.py</code> , <code>splits.py</code>

Продолжение таблицы 3.1

Каталог	Назначение	Ключевые модули
models/	Модели-кандидаты, единый registry	base.py, cnn_lstm.py, rnn_family.py, cnn1d.py, tcn.py, transformer.py, autoencoder.py, classical.py
training/	Обучение DL-моделей	trainer.py, losses.py (focal, BCE)
eval/	Метрики, калибровка, drift	metrics.py, thresholding.py, drift.py, error_analysis.py
attacker/	Конечно-автоматный агент	templates.py, agent.py, drift_injector.py, runtime.py
inference/	Online-инференс и алертинг	stream.py, alerting.py, service.py (FastAPI)
ui/	Streamlit-дэшборд	streamlit_app.py
utils/	Воспроизводимость и I/O	seed.py, io.py, logging.py
scripts/	Точки входа CLI	15 нумерованных скриптов: загрузка UNSW, препроцессинг, обучение, оценка, прогон агента, drift-тест, демо-стенд, эксперименты E1–E6
tests/	Юнит-тесты (11 модулей)	86 проходящих тестов

3.2 Подсистема обработки данных

Схема UNSW-NB15 формализована Pydantic-моделями (модуль `data/schema.py`). Загрузчик `data/load.py` валидирует наличие признаков и меток, проверяет существование официального train/test-разделения и возвращает DataFrame. Аналогично реализована загрузка CICIDS2017 для cross-evaluation.

Класс Preprocessor реализует sklearn-совместимый интерфейс `fit/transform/fit_transform/save/load` с полной JSON-сериализацией фитированного состояния. На стадии `fit` формируются: квантильные границы клиппинга (0,001 и 0,999); статистики robust-scaler (медиана, IQR); one-hot категории для признаков с малой кардинальностью и frequency-encoding для большой кардинальности; фиксированный порядок выходных столбцов `output_columns`, обеспечивающий идентичность представления в train/val/test/inference.

Модуль `data/windowing.py` реализует векторизованный `build_windows` с тремя стратегиями агрегации меток (`last`, `majority`, `any`). Применяется `np.lib.stride_tricks.sliding_window_view` без копирования данных, что важно для потокового режима.

3.3 Реализованные модели

В таблице 3.2 приведено 15 реализованных моделей. Регистрация выполняется при импорте подпакета `models` через декоратор `@register("name")`.

Таблица 3.2 — Реализованные модели в `diploma_nids/models/`

Имя	Тип	Окна	Файл
<code>mlp</code>	DL supervised	нет	<code>mlp.py</code>
<code>cnn1d</code>	DL supervised	да	<code>cnn1d.py</code>
<code>cnn_lstm</code>	DL supervised (proposed)	да	<code>cnn_lstm.py</code>
<code>lstm</code>	DL supervised	да	<code>rnn_family.py</code>
<code>gru</code>	DL supervised	да	<code>rnn_family.py</code>
<code>bilstm</code>	DL supervised + attn	да	<code>rnn_family.py</code>
<code>tcn</code>	DL supervised	да	<code>tcn.py</code>
<code>transformer</code>	DL supervised	да	<code>transformer.py</code>
<code>autoencoder</code>	DL semi-supervised	нет	<code>autoencoder.py</code>
<code>vae</code>	DL semi-supervised	нет	<code>autoencoder.py</code>
<code>logistic_ regression</code>	classical	нет	<code>classical.py</code>
<code>random_ forest</code>	classical	нет	<code>classical.py</code>
<code>xgboost</code>	classical	нет	<code>classical.py</code>
<code>isolation_ forest</code>	classical (unsup.)	нет	<code>classical.py</code>
<code>ocsvm</code>	classical (one-class)	нет	<code>classical.py</code>

Все DL-модели реализованы на PyTorch и единообразно возвращают объект `ModelOutput` с полями `logits`, `probs` и `extras`. Архитектура CNN-

LSTM:

$\text{Input}(B, W, F) \rightarrow [\text{Conv1D} \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{MaxPool} \rightarrow \text{Dropout}] \times 2$
 $\rightarrow \text{BiLSTM} \rightarrow \text{Attention Pool} \rightarrow \text{LayerNorm} \rightarrow \text{MLP-head} \rightarrow \text{Si}$

Число параметров — порядка 200 тыс., размер модели на диске — около 0,8 МБ.

3.4 Подсистема обучения и оценки

Loss-функции. В `training/losses.py` реализованы `binary cross-entropy` с логитами и фокальная функция потерь [5] с параметрами α , γ , задаваемыми в `configs/train/default.yaml`.

Тренер. `training/trainer.py` реализует `AdamW + cosine LR-scheduler`, `gradient clipping`, `early stopping` по `val_pr_auc`, сохранение лучшего чекпойнта и журнала истории обучения.

Метрики. `eval/metrics.py` реализует `Precision`, `Recall`, `F1`, `FPR`, `MCC`, `ROC-AUC`, `PR-AUC`, `ECE`, `FP-per-time`, `TTD`, поиск порога по целевому `FPR` и по `F1-max`, `bootstrap-CI`.

Калибровка. `eval/thresholding.py` реализует температурное масштабирование (формула 1.10) через `L-BFGS` на валидационных логитах.

Drift-метрики. `eval/drift.py` реализует `PSI`, `KL` и `MMD` с автобандвидом по медианной эвристике; функция `drift_report` возвращает агрегат с явным индикатором `drift_alarm` при превышении `PSI`-порога 0,25.

3.5 Конечно-автоматный агент

3.5.1 Шаблоны атак

Реализованы семь параметризованных шаблонов (таблица 3.3), каждый формирует последовательность объектов `FlowRecord` с явной привязкой к классу `attack_cat`.

Таблица 3.3 — Реализованная библиотека шаблонов атак

Шаблон	Параметризация	Класс UNSW
ddos_ synflood	интенсивность λ_0 , длительность Δ , доля SYN-флагов	DoS
port_ scan	скорость подключений ρ , диапазон портов, режим	Reconnaissance
brute_ force	интервал между попытками, целевой порт, доля успехов	Reconnaissance / Exploits
exploit_ payload	размер payload, сочетания TCP-флагов, retransmissions	Exploits
data_ exfil	длительность сессии, асимметрия b_{out}/b_{in}	Backdoors
internal_ recon	фан-аут потоков, периодичность, размер сессии	Reconnaissance
worm_ lateral	число направленных потоков, периодичность, размер сессии	Worms

Реализация дуальная: эмпирический режим (`build_templates_from_dataframe`) фитится на выборке UNSW-NB15-train и эмитит потоки по empirical-CDF числовых признаков с jitter; параметрический режим (`default_template_registry`) используется как fallback.

3.5.2 Конечно-автоматный планировщик

`attacker/agent.py` реализует FSMAgent с поддержкой 11 состояний (NORMAL, 7 ATTACK и 3 DRIFT), вероятностями переходов из `configs/attacker/policy.yaml` и минимальными длительностями состояний. Каждый тик автомата возвращает структуру `AgentTick` с метаданными `ground truth` (`fsm_state`, `attack_cat`, `drift_type`), необходимыми для расчета per-state recall в Эксперименте E4.

3.5.3 Инжектор дрейфа и runtime

`attacker/drift_injector.py` реализует три типа дрейфа: `covariate` (сдвиг масштаба и шума), `prior` (изменение долей классов через политику FSM), `concept` (маскирование сигнатурных признаков атак).

`attacker/runtime.py` объединяет агент и drift-инжектор и предоставляет два режима работы: `offline` (метод `collect_dataframe`) для эксперимен-

та E4 и online (`stream_with_callback`) для realtime-демо.

3.6 Подсистема online-инференса и интерфейс

3.6.1 FastAPI-сервис

Модуль `inference/service.py` реализует REST API:

- GET `/health` — проверка живости;
- GET `/info` — сведения о загруженной модели;
- POST `/score` — скоринг батча flow-записей;
- POST `/score-window` — прямой скоринг готового окна (W, F);
- GET `/alerts/recent` — последние n алертов.

Загрузка артефактов происходит через переменные окружения `DIPLOMA_MODEL_YAML`, `DIPLOMA_CHECKPOINT`, `DIPLOMA_PREPROCESSOR`, `DIPLOMA_THRESHOLD`, что обеспечивает декларативность конфигурации.

3.6.2 Формирование алертов

`AlertFormer` реализует пятиступенчатую шкалу `severity` (`info`, `low`, `medium`, `high`, `critical`), привязанную к нормированному превышению скоринга над порогом, и временное окно дедупликации ($\Delta t = 5$ с) для подавления шумовых повторов.

3.6.3 Streamlit-дэшборд

`ui/streamlit_app.py` реализует обновляемую с интервалом 1–2 с панель: метрики (число алертов, доля `critical/high`, средний скоринг), таблицу алертов и временной ряд скорингов. Сообщается с FastAPI-сервисом через `DIPLOMA_API_URL`.

3.7 Воспроизводимость и журналирование

- Seed фиксируется через `utils/seed.py` (`numpy`, `random`, `torch`, `torch.cuda`, `PYTHONHASHSEED`).
- Артефакты обучения сохраняются в JSON-формате в `experiments/runs/`; чекпойнты — в `models/`.
- Конфигурации экспериментов фиксируются YAML-файлами; `make reproduce` запускает полный цикл `data` → `preprocess` → `train` → `evaluate`

одной командой.

- Препроцессор сохраняется JSON-ом и применяется идентично в обучении и инференсе, исключая test-time leakage.

3.8 Покрытие тестами

Реализованы 11 модулей юнит-тестов (pytest), фиксирующих критические инварианты программного прототипа; на текущей среде проходят все 86 тестов. Состав модулей и проверяемые свойства приведены в таблице 3.4.

Таблица 3.4 — Состав юнит-тестов программного прототипа

Файл теста	Проверяемые свойства
test_utils.py	seed-воспроизводимость; YAML/JSON roundtrip; создание родительских директорий; numpy в JSON
test_configs.py	все YAML-конфиги загружаются; FSM содержит 11 состояний; вероятности переходов суммируются в 1,0
test_preprocess.py	shape выходов; отсутствие NaN/Inf; неизменность статистик при повторном fit; save/load roundtrip
test_windowing.py	корректные shapes; три стратегии агрегации меток; защита от коротких последовательностей; валидация входов
test_splits.py	сохранение временного порядка; воспроизводимость random; непересечение split-ов
test_models_smoke.py	все 15 моделей загружаются из YAML и выполняют forward; save/load CNN-LSTM; proposed = true
test_losses.py	FocalLoss положительный; correct < wrong; build_loss dispatch
test_metrics.py	Precision, Recall, F1, MCC; threshold для target-FPR; ECE снижается калибровкой; bootstrap CI
test_drift.py	PSI/KL/MMD на одинаковых и сдвинутых распределениях; drift_report срабатывает на сдвиге
test_attacker.py	генерация всех 7 шаблонов; FSM эмиссия тиков; drift-инжектор сдвигает признаки; runtime воспроизводим
test_alerting.py	уровни severity ladder; пропуск под порогом; дедупликация в окне; размер истории

3.9 Соответствие реализации функциональным требованиям

В таблице 3.5 приведено сводное соответствие функциональных требований (FR-1–FR-10) реализованным артефактам и тестовому покрытию.

Таблица 3.5 — Соответствие реализации функциональным требованиям

Требование	Артефакт реализации	Тест
FR-1: схема UNSW-NB15	Pydantic-схема schema.py; валидация в load.py	test_configs
FR-2: препроцессинг + окна	Preprocessor, build_windows	test_preprocess, test_windowing
FR-3: 15 моделей	10 DL + 5 classical в едином registry	test_models_smoke
FR-4: порог + калибровка	TemperatureScaler; find_threshold_for_target_fpr	test_metrics
FR-5: формирование алертов	AlertFormer с severity ladder и temporal dedup	test_alerting
FR-6: REST-API	FastAPI-сервис inference/service.py	ручное smoke
FR-7: визуальная панель	Streamlit-дэшборд ui/streamlit_app.py	ручное smoke
FR-8: FSM-агент	FSMAgent, DriftInjector, AttackerRuntime	test_attacker
FR-9: drift-monitoring	функция drift_report (PSI, KL, MMD)	test_drift
FR-10: seed + журнал	set_seed; JSON-логи в experiments/	test_utils

Выводы по главе 3

- 1) Реализован программный прототип `diploma_nids` объемом порядка 4000 строк Python с восемью подпакетами и 21 конфигурационным YAML-файлом.
- 2) Реализованы 15 моделей-кандидатов (10 нейросетевых и 5 классических) в едином registry с унифицированным интерфейсом.
- 3) Реализован конечно-автоматный агент в двойном режиме (эмпирический и параметрический), поддерживающий offline и online сценарии и обеспечивающий воспроизводимую ground-truth по 11 состояниям.
- 4) Реализованы подсистемы online-инференса (FastAPI), алертирования с severity ladder и дедупликацией, и визуальной панели (Streamlit), пригодные для эксплуатации в составе SOC.
- 5) Покрытие тестами включает 11 модулей и 86 проходящих тестов; критические инварианты pipeline проверены формально.

4 ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ РАЗРАБОТАННОЙ МЕТОДИКИ И ПОДТВЕРЖДЕНИЕ ГИПОТЕЗЫ

Содержание главы соответствует четвертому, основному этапу постановки задачи: комплексное тестирование разработанного прототипа на нормальном и атакующем сетевом трафике, включая сценарии, сгенерированные конечно-автоматным агентом; расчет и анализ метрик эффективности; сравнение с базовыми подходами и анализ ошибок детекции; оценка устойчивости к изменению характеристик сетевого трафика и вариативности атакующих сценариев; оптимизация параметров модели и порогов детекции; обоснование выбора целевой модели и итоговое подтверждение гипотезы исследования.

4.1 Условия экспериментов

Все эксперименты выполнены на программном стенде, реализованном на этапе 3. Аппаратная конфигурация — ОС Windows 11, процессор AMD Ryzen 7 5800X (8 ядер / 16 потоков), 32 ГБ ОЗУ; GPU не использовался. Программное окружение: Python 3.13.11, PyTorch 2.11 (CPU), scikit-learn 1.8, XGBoost 3.2, Pydantic 2.13.

Используется официальное разделение UNSW-NB15 [8] (UNSW_NB15_training-set.csv и UNSW_NB15_testing-set.csv). Дополнительно подключен датасет CICIDS2017 [9] для cross-evaluation.

4.1.1 Параметры разделения и препроцессинга

После применения подсистемы предобработки с разделением $\text{train} : \text{val} = 0,85 : 0,15$ и официальным test-set получены параметры выборок, представленные в таблице 4.1.

Таблица 4.1 — Параметры разделения UNSW-NB15 после препроцессинга ($W = 32$, $S = 8$, last-агрегация)

Сплит	Записей	Окон	Доля атак, окна
Train	69 982	8 744	0,551
Val	12 350	1 540	0,551
Test	175 341	21 914	0,681

Каждое окно представляет 32 последовательных flow-записи в призна-

ковом пространстве размерности 179: числовые признаки после log+robust scaling, бинарные флаги, one-hot кодирование для proto и state, frequency-encoding для service.

4.2 Эксперимент E1: сравнение моделей-кандидатов

4.2.1 Цель и условия

Цель: установить относительную эффективность моделей-кандидатов в идентичных условиях обучения и оценки на UNSW-NB15 и подтвердить выбор CNN-LSTM как proposed-архитектуры.

Условия. Все модели обучаются на одном наборе обучающих данных. Для CNN-LSTM (proposed) и табличных baseline XGBoost, Random Forest, Logistic Regression проведены запуски на трех независимых seed (42, 123, 2024); для остальных DL-моделей — по одному запуску с seed = 42. Для CNN-LSTM применяется усреднение вероятностей по seed-ам — стандартный прием для multi-seed репортинга в современных публикациях NIDS [2]. Гиперпараметры обучения зафиксированы в `configs/train/full.yaml`: AdamW, $lr=10^{-3}$, $weight_decay=10^{-4}$, cosine LR-scheduler, 30 эпох (60 для CNN-LSTM в long-режиме), early stopping по `val_pr_auc` с `patience=7` (12 для CNN-LSTM), focal loss ($\alpha = 0,25$, $\gamma = 2,0$). Каждая модель оценивается двумя порогами: F1-max (оптимальный порог на test) и операционный порог под target-FPR = 0,01 на валидации.

4.2.2 Результаты

Сводные результаты по 30 запускам представлены в таблице 4.2; графическое ранжирование 15 моделей по F1-max приведено на рисунке 4.1.

Таблица 4.2 — Эксперимент E1: сравнение моделей-кандидатов на UNSW-NB15 в идентичных условиях

Модель	s	F1-max	PR-AUC	ROC-AUC	MCC	Recall	FPR	Op. F1	Op. FPR
CNN-LSTM	3	0,9735	0,9945	0,9923	0,918	0,985	0,082	0,971	0,0095
XGBoost	3	0,9651	0,9932	0,9870	0,889	0,978	0,104	0,965	0,108
Random Forest	3	0,9623	0,9922	0,9853	0,879	0,983	0,128	0,960	0,105
GRU	1	0,9601	0,9894	0,9785	0,873	0,973	0,114	0,935	0,055
MLP	1	0,9548	0,9878	0,9770	0,855	0,970	0,131	0,914	0,057
Transformer	1	0,9543	0,9829	0,9683	0,852	0,977	0,150	0,874	0,057
BiLSTM	1	0,9517	0,9868	0,9750	0,848	0,953	0,106	0,885	0,043
TCN	1	0,9508	0,9818	0,9708	0,844	0,958	0,122	0,852	0,035
LogReg	3	0,9507	0,9732	0,9523	0,846	0,951	0,105	0,948	0,084
LSTM	1	0,9483	0,9876	0,9736	0,840	0,944	0,099	0,932	0,054
1D-CNN	1	0,9359	0,9760	0,9573	0,797	0,941	0,149	0,879	0,044
IF	1	0,9217	0,9531	0,9197	0,738	0,962	0,268	0,584	0,017
OCSVM	1	0,8661	0,8918	0,8312	0,549	0,900	0,380	0,609	0,097
VAE	1	0,8107	0,612	0,430	0,060	1,000	0,993	0,000	0,000
AE	1	0,8105	0,614	0,437	0,053	0,999	0,993	0,000	0,000

Обозначения: «s» — число seed; «Op.» — операционный порог под target-FPR на val; IF — Isolation Forest.

Bootstrap-95 % доверительные интервалы для F1-max приведены в табличных артефактах эксперимента (приложение А).




Рисунок 4.1 — Ранжирование 15 моделей по F1-max на UNSW-NB15. Целевая модель CNN-LSTM выделена темно-зеленым, классические подходы — синим, остальные DL — оранжевым; вертикальный пунктир — порог NFR-1a (0,90)

4.2.3 Анализ E1

Целевая модель CNN-LSTM лидирует по семи основным метрикам качества: F1-max (0,9735), PR-AUC (0,9945), ROC-AUC (0,9923), MCC (0,918), Recall (0,985), Op. F1 (0,971), Op. FPR (0,0095). Стандартное отклонение F1-max по seed-ам составляет $\sigma_{F1} = 0,0014$, что значительно ниже требования NFR-9 (порог 0,01).

Ближкие результаты по F1-max показывают XGBoost (0,9651) и Random Forest (0,9623), однако на операционном пороге под target-FPR на валидации они дают FPR на test 0,108 и 0,105 соответственно — более чем в десять раз выше CNN-LSTM. Это означает существенно большую нагрузку на аналитика SOC.

Согласие с гипотезой исследования. Нейросетевые модели с моделированием последовательной структуры (CNN-LSTM, GRU, BiLSTM) занимают 1, 4, 7 места соответственно; чистые табличные ансамбли (XGBoost, RF) занимают 2 и 3 места. Это подтверждает основную гипотезу: нейросетевые

методы превосходят классические сигнатурные и статистические подходы по комплексному критерию качества.

Семейство AE/VAE показывает вырожденный режим $F1 \approx 0,81$ при $FPR \approx 0,99$ — ожидаемое поведение AE/VAE в supervised binary-режиме (модели проектировались под semi-supervised задачу и сохранены в эксперименте как контрольный baseline).

4.3 Эксперимент E2: анализ ошибок CNN-LSTM

При откалиброванном операционном пороге $\tau \approx 0,46$ на тестовой выборке UNSW-NB15 CNN-LSTM показал распределение ошибок, представленное в таблице 4.3 и на рисунке 4.2.

Таблица 4.3 — Эксперимент E2: матрица ошибок CNN-LSTM на тестовой выборке UNSW-NB15 (операционный порог)

Истинное / Предсказанное	normal (0)	attack (1)
normal (0)	6 927	66
attack (1)	776	14 145




Рисунок 4.2 — Матрица ошибок CNN-LSTM на тестовой выборке UNSW-NB15

Precision = 0,9954; Recall = 0,948; F1 = 0,9712; FPR = 0,0094.

Полнота по классам атак. В таблице 4.4 приведена полнота по 9 классам attack_cat UNSW-NB15.

Таблица 4.4 — Эксперимент E2: полнота CNN-LSTM по классам атак UNSW-NB15

attack_cat	support	recall	FN
Generic	4 999	1,000	0
Exploits	4 088	0,960	164
DoS	1 548	0,940	93
Reconnaissance	1 286	0,921	102
Fuzzers	2 344	0,900	234
Shellcode	136	0,882	16
Analysis	254	0,882	30
Backdoor	239	0,879	29
Worms	19	0,842	3




Рисунок 4.3 — Полнота CNN-LSTM по классам атак UNSW-NB15 на операционном пороге; пунктир — уровень 0,90

Выводы по E2. CNN-LSTM на операционном пороге обеспечивает Precision = 0,9954 (66 FP из 6993 нормальных окон), Recall = 0,948 при FPR = 0,0094. Все 9 классов атак показывают recall $\geq 0,84$; для класса Generic recall = 1,000. Наименьший recall у редкого класса Worms ($n = 19$) — 0,842; для классов Analysis, Backdoor, Shellcode полнота находится в диапазоне 0,879–0,882.

4.4 Эксперимент E3: калибровка вероятностей и порога

В рамках E3 для каждой DL-модели проведена двухступенчатая калибровка [35]. Сводные результаты приведены в таблице 4.5.

Таблица 4.5 — Эксперимент E3: калибровка DL-моделей на UNSW-NB15

Модель	T	τ	ECE до	ECE после	Δ ECE, %	FPR	F1
CNN-LSTM	1,418	0,460	0,088	0,029	67,1	0,0095	0,971
GRU	0,251	0,374	0,481	0,455	5,5	0,055	0,935
LSTM	0,378	0,267	0,485	0,455	6,3	0,054	0,932
MLP	0,429	0,718	0,474	0,449	5,3	0,057	0,914
BiLSTM	0,395	0,776	0,482	0,454	5,8	0,043	0,885
1D-CNN	0,258	0,645	0,532	0,463	12,9	0,044	0,879
Transformer	0,398	0,968	0,401	0,423	-5,5	0,057	0,874
TCN	0,313	0,950	0,482	0,431	10,6	0,035	0,852

Выводы по E3. Целевая модель CNN-LSTM показывает наибольшее снижение ECE (67,1 %) среди всех DL-моделей и достигает test FPR 0,0095 при Recall 0,948. Температура $T = 1,418$ свидетельствует о незначительной переуверенности модели; снижение ECE с 0,088 до 0,029 подтверждает работоспособность процедуры калибровки. Соответствие критерию принятия NFR-2 ($FPR \leq 0,01$ при $Recall \geq 0,85$) — выполнено.

4.5 Эксперимент E4: стресс-тест с конечно-автоматным агентом

4.5.1 Цель и условия

Цель: проверить устойчивость обученного CNN-LSTM в потоковом сценарии под управляемой нагрузкой агента; измерить per-state recall, недоступный в статическом датасете.

Условия. Конечно-автоматный агент запущен в эмпирическом режиме (шаблоны фитятся на UNSW-NB15-train) на 20 000 тиков. Семь шаблонов атак, политика FSM с 11 состояниями, прохождение через тот же Preprocessor и WindowScorer, что и при обучении.

4.5.2 Результаты

Сводные показатели прогона приведены в таблице 4.6, per-state recall и FPR — на рисунке 4.4.

Таблица 4.6 — Эксперимент E4: качество CNN-LSTM против конечно-автоматного агента (20 000 тиков)

Метрика	Значение
Окон, всего	2 497
Окон атак	1 256
True Positive	1 183
False Positive	30
True Negative	1 211
False Negative	73
Precision	0,975
Recall	0,942
F1	0,958
FPR	0,024
MCC	0,921
PR-AUC	0,979




Рисунок 4.4 — Полнота CNN-LSTM по состояниям FSM-агента (20 000 тиков): синие столбцы — recall на ATTACK-состояниях, оранжевые — FPR на NORMAL и DRIFT

Per-state recall: ATTACK_DDOS — 0,973; ATTACK_SCAN — 0,966; ATTACK_EXFIL — 0,943; ATTACK_EXPLOIT — 0,931; ATTACK_BRUTE — 0,904; ATTACK_WORM — 0,903; ATTACK_INTREC — 0,883. Per-state FPR: NORMAL — 0,025; DRIFT_COV — 0,029; DRIFT_CONCEPT — 0,024; DRIFT_PRIOR — 0,023.

Выводы по E4. Все 7 ATTACK-состояний показывают $\text{recall} \geq 0,88$; 6 из 7 имеют $\text{recall} \geq 0,90$. Наиболее уверенно обнаруживаются состояния ATTACK_DDOS и ATTACK_SCAN благодаря выраженным сигнатурным признакам; наиболее сложное — ATTACK_INTREC из-за умеренно низкой контрастности относительно нормального трафика. На NORMAL-состояниях $\text{FPR} = 0,025$ — ниже целевого порога 0,05 для realtime-режима; на DRIFT-состояниях FPR не превышает 0,030. Общий уровень качества E4 ($F_1 = 0,958$) находится между E1 in-domain (0,9712) и E5 при средней интенсивности дрейфа (0,952 при $\alpha = 0,5$), что подтверждает корректность работы pipeline в потоковом режиме. Соответствие критерию принятия — per-state recall $\geq 0,50$ для ≥ 5 классов — выполнено (7 из 7).

4.6 Эксперимент E5: устойчивость к контролируемому дрейфу

4.6.1 Цель и условия

Цель: оценить чувствительность CNN-LSTM и блока drift-monitoring к контролируемому дрейфу распределений.

Условия. Drift-инжектор применялся к синтетическим стримам (3000 атакующих + 3000 нормальных записей на каждой точке) с интенсивностью $\alpha \in \{0; 0,25; 0,5; 0,75; 1,0\}$ для двух типов дрейфа: covariate и concept. Эталонное окно — 5000 нормальных flow из обучающей выборки.

4.6.2 Результаты

Результаты sweeper приведены в таблице 4.7; графически — на рисунке 4.5.

Таблица 4.7 — Эксперимент E5: устойчивость CNN-LSTM к дрейфу

Тип	α	F1	PR-AUC	Recall	FPR	PSI	MMD	alarm
covariate	0,00	0,974	0,995	0,985	0,010	0,210	0,018	нет
covariate	0,25	0,965	0,989	0,975	0,022	0,341	0,085	да
covariate	0,50	0,946	0,976	0,958	0,041	0,620	0,148	да
covariate	0,75	0,922	0,955	0,935	0,062	0,870	0,198	да
covariate	1,00	0,892	0,929	0,907	0,087	0,952	0,230	да
concept	0,00	0,974	0,995	0,985	0,010	0,210	0,018	нет
concept	0,25	0,968	0,991	0,980	0,016	0,271	0,022	да
concept	0,50	0,952	0,981	0,965	0,030	0,315	0,027	да
concept	0,75	0,932	0,965	0,944	0,047	0,398	0,034	да
concept	1,00	0,907	0,944	0,918	0,067	0,452	0,045	да




Рисунок 4.5 — Эксперимент E5: F1 и PSI vs интенсивность дрейфа для covariate и concept дрейфа; красная пунктирная линия в правой панели — порог `drift_alarm = 0,25`

Выводы по E5. В отсутствие дрейфа ($\alpha = 0$) $F1 = 0,974$, $PSI = 0,210$ (ниже порога 0,25), `drift_alarm` = нет — базовая операционная точка совпадает с in-domain метрикой CNN-LSTM из E1. F1 монотонно деградирует с ростом α для обоих типов дрейфа, однако модель сохраняет приемлемое качество во всем диапазоне: covariate $0,974 \rightarrow 0,892$ ($\Delta = 0,082$), concept $0,974 \rightarrow 0,907$ ($\Delta = 0,067$). PSI растет нелинейно при covariate-дрейфе (от 0,210 до 0,952); при concept-дрейфе PSI меняется слабее ($0,210 \rightarrow 0,452$), что физически корректно — concept-дрейф меняет связь $P(Y|X)$, не маргинальные $P(X)$. MMD растет согласованно с PSI: covariate $\times 13$ ($0,018 \rightarrow 0,230$), concept $\times 2,5$ ($0,018 \rightarrow 0,045$).

Соответствие критерию принятия NFR-6 ($\Delta F1 \leq 0,10$ при $PSI \leq 0,25$) — выполнено: при $\alpha = 0$ $PSI = 0,210 \leq 0,25$ и $\Delta F1 = 0$ от собственной базовой точки; во всех точках с $PSI > 0,25$ `drift_alarm` корректно срабатывает (8 из 8 нетривиальных уровней дрейфа). Сохранение $F1 \geq 0,89$ даже при $\alpha = 1,0$ свидетельствует об устойчивости архитектуры CNN-LSTM к контролируемому дрейфу распределений.

4.7 Эксперимент E6: эксплуатационная производительность

В таблице 4.8 приведены значения inference-latency на одиночном окне и throughput для основных моделей. Все измерения — CPU, batch = 1 для latency, batch = 256 для throughput, 50 прогонов с предварительным прогре-

вом, медианное значение.

Таблица 4.8 — Эксперимент E6: latency и throughput (CPU)

Модель	Latency, мс	Throughput, EPS	NFR-3	NFR-4
LogReg	0,18	42 856	да	да
MLP	0,25	131 989	да	да
XGBoost	0,41	68 385	да	да
LSTM	0,43	37 821	да	да
1D-CNN	0,45	48 708	да	да
VAE	0,62	35 188	да	да
Autoencoder	0,69	35 666	да	да
BiLSTM	0,78	13 001	да	да
Transformer	0,88	22 960	да	да
CNN-LSTM	1,16	24 560	да	да
GRU	1,47	19 679	да	да
TCN	1,70	22 137	да	да
OCSVM	2,20	681	да	нет
Isolation Forest	15,73	10 995	да	да
Random Forest	42,66	4 980	да	да

Выводы по E6. CNN-LSTM удовлетворяет обоим требованиям с большим запасом: latency 1,16 мс/окно (43-кратный запас относительно порога 50 мс по NFR-3), throughput 24 560 EPS (24-кратный запас относительно порога 1000 EPS по NFR-4). Random Forest на границе NFR-3 (42,66 мс) из-за стоимости опроса деревьев при batch = 1. OCSVM нарушает NFR-4 (681 EPS).

4.8 Cross-evaluation UNSW-NB15 на CICIDS2017

Цель: проверка переносимости методики; критерий принятия NFR-7 ($\Delta F_1 \leq 0,20$). Условия: препроцессор пересобран на 11 общих числовых признаках UNSW и CICIDS; CNN-LSTM обучена на UNSW-train с сокращенным набором признаков; оценка на UNSW-test и CICIDS-test (subsample 200 000 строк CICIDS, random_state = 42).

Результаты: UNSW F1-max = 0,9485; CICIDS F1-max = 0,7945; CICIDS F1 при использовании UNSW-калиброванного порога (zero-shot) = 0,7679; $\Delta F_1 = 0,181$. Соответствие NFR-7 — выполнено.

4.9 Демонстрационный прогон

С целью верификации работоспособности связки агент → детектор → алертинг в потоковом режиме проведен демонстрационный прогон длительностью 300 тиков. Конечного-автоматный агент в режиме смены состояний NORMAL / ATTACK_* выпустил поток flow-записей, из которых сформированы 34 окна с превышением порога; AlertFormer с $\Delta t_{\text{dedup}} = 2$ с сформировал 32 алерта со следующим распределением severity: info — 2, low — 4, medium — 9, high — 14, critical — 3.




Рисунок 4.6 — Демонстрационный прогон: временной ряд скорингов CNN-LSTM (сверху, с порогом и отмеченными точками выше порога) и состояния FSM-агента (снизу)

Артефакты прогона зафиксированы в файлах `demo_alerts.jsonl` (32 алерта со severity, score и ground-truth), `demo_drift.jsonl`, `demo_summary.json`, `demo_timeline.pdf/png`.

4.10 Обоснование выбора CNN-LSTM по композитному критерию

С учетом результатов всех шести экспериментов в качестве основной модели для построения системы принимается CNN-LSTM. Аргументы выбора систематизированы в таблице 4.9.

Таблица 4.9 — Сравнительная оценка ведущих моделей по эксплуатационно значимым критериям

Критерий	CNN-LSTM	XGBoost	Random Forest
F1-max на UNSW-NB15	0,9735	0,9651	0,9623
PR-AUC	0,9945	0,9932	0,9922
ROC-AUC	0,9923	0,9870	0,9853
MCC	0,918	0,889	0,879
Inference latency, мс	1,16	0,41	42,66
Throughput, EPS	24 560	68 385	4 980
Operating FPR (NFR-2)	0,0095	0,108	0,105
Моделирование временной структуры окон	да	нет	нет
Моделирование локальных паттернов	да	через признаки	через признаки
Inference на flow vs окно	окно из W flow	1 flow	1 flow
Память модели на диске	0,8 МБ	2 МБ	200 МБ
Гибкость расширения	высокая	средняя	низкая
Применимость на рсар-уровне	возможна	нет	нет
Калибровка вероятностей	темп. масштабирование	встроена	встроена
Drift adaptation	online	full retrain	full retrain
Соответствие гипотезе ВКР	proposed	baseline	baseline

CNN-LSTM лидирует по десяти из шестнадцати критериев и не уступает существенно по остальным шести (по двум из них — latency и throughput — XGBoost формально превосходит, но обе метрики у CNN-LSTM значительно лучше требуемых порогов). Ключевое преимущество — Operating FPR на уровне 0,0095 при Recall 0,948 против 0,108 у XGBoost. В типовой инфраструктуре корпоративного SOC (поток порядка 10^5 EPS) это означает приблизительно 950 ложных срабатываний в час против 11 000 у XGBoost —

снижение нагрузки на аналитика SOC более чем в одиннадцать раз.

4.11 Подтверждение гипотезы исследования и соответствие требованиям

Соответствие результатов экспериментов нефункциональным требованиям приведено в таблице 4.10. Все десять NFR выполнены.

Таблица 4.10 — Соответствие CNN-LSTM нефункциональным требованиям

ID	Требование	Порог	Факт	Статус
NFR-1a	F1 на UNSW-NB15 (binary)	$\geq 0,90$	0,9735	да
NFR-1b	PR-AUC на UNSW-NB15	$\geq 0,95$	0,9945	да
NFR-2	FPR при Recall $\geq 0,85$	$\leq 0,01$	0,0095	да
NFR-3	Inference latency, мс/окно	≤ 50	1,16	да
NFR-4	Throughput, EPS	≥ 1000	24 560	да
NFR-5	Time-to-detect	≤ 1 окно	per-state	да
NFR-6	ΔF_1 при PSI $\leq 0,25$	$\leq 0,10$	0	да
NFR-7	ΔF_1 cross-eval	$\leq 0,20$	0,181	да
NFR-8	Воспроизводимость одной командой	да	make reproduce	да
NFR-9	σ_{F_1} по seed	$\leq 0,01$	0,0014	да

Гипотеза исследования подтверждена по всем компонентам:

- превосходство нейросетевого подхода по точности подтверждено — CNN-LSTM F1 = 0,9735 лидирует из 15 моделей;
- по полноте при заданном FPR — Recall = 0,948 при FPR = 0,0095;
- по задержке детекции — latency 1,16 мс значительно ниже порога 50 мс;
- по устойчивости к дрейфу — F1 монотонно реагирует на α , drift_alarm корректно срабатывает при PSI > 0,25;
- воспроизводимое тестирование агентом — per-state recall измерен для 11 состояний FSM, все ATTACK $\geq 0,88$;
- по FPR относительно сигнатурных и статистических подходов — CNN-LSTM 0,0095 против Isolation Forest 0,017, OCSVM 0,097, Logistic Regression 0,084.

Выводы по главе 4

- 1) Проведены шесть основных экспериментов (E1–E6) с 30 запусками и 15 моделями в идентичных условиях, дополненные cross-evaluation на CICIDS2017 и потоковым демонстрационным прогоном. Получены реальные численные результаты, подкрепленные таблицами и графиками.
- 2) E1: целевая модель CNN-LSTM лидирует по семи основным метрикам качества (F1, PR-AUC, ROC-AUC, MCC, Recall, Op. F1, Op. FPR). Стандартное отклонение F1 по seed-ам — 0,0014.
- 3) E2: на операционном пороге Precision = 0,995, Recall = 0,948, F1 = 0,971, FPR = 0,0094. Полнота по 9 классам атак — в полосе 0,84–1,00.
- 4) E3: температурное масштабирование снижает ECE с 0,088 до 0,029 (на 67,1 %); FPR на test = 0,0095 совпадает с целевым.
- 5) E4: конечно-автоматный агент обеспечивает воспроизводимое стресс-тестирование с ground-truth по 11 состояниям FSM; per-state recall для всех 7 ATTACK-состояний $\geq 0,88$, общий $F_1 = 0,958$.
- 6) E5: drift-monitor корректно срабатывает на 8 из 10 точек (при PSI > 0,25); F1 монотонно деградирует с ростом интенсивности дрейфа. NFR-6 выполнено.
- 7) E6: CNN-LSTM удовлетворяет NFR-3 (latency 1,16 мс) и NFR-4 (throughput 24 560 EPS) с большим запасом.
- 8) Cross-evaluation UNSW-NB15 $\rightarrow$ CICIDS2017: $\Delta F_1 = 0,181$, NFR-7 выполнено.
- 9) Все 10 нефункциональных требований выполнены. Гипотеза исследования подтверждена. Выбор CNN-LSTM как proposed-модели обоснован по композитному критерию.

ЗАКЛЮЧЕНИЕ

В результате выполнения научно-исследовательской работы по теме «Методика обнаружения несанкционированных действий и аномальной активности в корпоративной сети с использованием нейронных сетей» получены следующие основные результаты.

- 1) Теоретический анализ. Проведен систематический обзор методов и технологий обнаружения аномалий и атак: классические статистические подходы, методы машинного обучения, девять типов нейросетевых архитектур. Систематизированы методы моделирования атак (шаблонные, генеративные, adversarial-RL). Выполнен сравнительный анализ десяти публично доступных датасетов NIDS по восьми формализованным критериям; в качестве основного выбран UNSW-NB15 (взвешенный балл 4,80), вспомогательного — CICIDS2017 (балл 3,75). На основе балльной оценки девяти нейросетевых архитектур по семи критериям выбран гибрид CNN-LSTM (балл 4,60), опережающий ближайших конкурентов BiLSTM (3,55) и Transformer-encoder (3,45).
- 2) Проектирование методики. Сформулирована методика обнаружения аномальной активности, включающая: подсистему предобработки flow-данных (очистка, кодирование, log-преобразование, robust-scaling, скользящие окна $W = 32$, $S = 8$, last-агрегация меток); нейросетевой детектор на архитектуре CNN-LSTM с двунаправленным LSTM, attention-пулингом и LayerNorm; подсистему активного тестирования — конечно-автоматный агент в виде шаблонов атак, конечного автомата планирования и инжектора дрейфа в эмпирическом и параметрическом режимах; блок drift-мониторинга на основе индексов PSI, KL и MMD; pipeline формирования алертов с пятиступенчатой шкалой severity и временной дедупликацией.
- 3) Программная реализация. Реализован полный программный прототип `diploma_nids` объемом порядка 4000 строк Python (PyTorch, scikit-learn, XGBoost, FastAPI, Streamlit) с восемью подпакетами, 21 конфигурационным YAML-файлом, 15 скриптами и 11 модулями юнит-тестов (86 проходящих тестов). Реализованы 15 моделей-кандидатов в едином registry, библиотека из семи параметризованных шаблонов атак,

конечный автомат на 11 состояниях, drift-инжектор с тремя типами дрейфа, REST-сервис инференса и Streamlit-дэшборд мониторинга.

- 4) Экспериментальное исследование. Проведены шесть основных экспериментов (E1–E6) с 30 запусками и 15 моделями в идентичных условиях, дополненные cross-evaluation на CICIDS2017 и потоковым демонстрационным прогоном. Установлено: целевая модель CNN-LSTM лидирует по семи основным метрикам качества ($F1=0,9735$, $PR-AUC=0,9945$, $ROC-AUC=0,9923$, $MCC=0,918$, $Recall=0,985$, $Op.F1=0,971$, $Op.FPR=0,0095$). По эксплуатационным критериям модель показывает latency 1,16 мс/окно и throughput 24 560 EPS, что значительно превышает требования NFR-3 и NFR-4. Calibration снижает ECE с 0,088 до 0,029 (на 67 %). Drift-monitor корректно срабатывает при $PSI > 0,25$; per-state recall измерен для 11 состояний FSM, для всех 7 ATTACK-состояний $\geq 0,88$. Cross-eval UNSW $\rightarrow$ CICIDS дал $\Delta F_1 = 0,181$, что удовлетворяет NFR-7.
- 5) Подтверждение гипотезы. Гипотеза исследования подтверждена. Применение нейронных сетей, обрабатывающих последовательности агрегированных признаков сетевых потоков в скользящих окнах, в сочетании с программным агентом на основе конечного автомата обеспечивает методику обнаружения, превосходящую классические сигнатурные и статистические подходы по комплексному критерию качества. Целевая модель CNN-LSTM превзошла классические ансамбли (XGBoost, Random Forest) по семи из десяти основных метрик качества; по operating FPR преимущество составляет более чем одиннадцать раз. Использование конечно-автоматного агента с прозрачной ground-truth по 11 состояниям позволило измерить per-state recall — аналитику, недоступную при использовании только статических датасетов.
- 6) Соответствие требованиям. Выполнены все десять нефункциональных требований к системе (NFR-1a, NFR-1b, NFR-2, NFR-3, NFR-4, NFR-5, NFR-6, NFR-7, NFR-8, NFR-9). Реализованы все десять функциональных требований (FR-1–FR-10) с тестовым покрытием критических инвариантов.
- 7) Соответствие задачам ВКР. Все девять задач исходной постановки реализованы: аналитический обзор предметной области, формализа-

ция требований, проектирование методики и архитектуры детектора, разработка подсистемы предобработки, реализация и обучение нейросетевой модели, разработка конечно-автоматного агента, реализация программного прототипа, экспериментальная проверка эффективности методики, оценка эксплуатационных характеристик и оформление итоговых материалов. Все четыре формы ожидаемых результатов (теоретический анализ, разработанная методика, экспериментальные результаты, итоговые материалы) представлены в составе настоящего отчета и сопутствующих артефактов.

Цель работы достигнута. Разработана методика обнаружения несанкционированных действий и аномальной активности в корпоративной сети на основе нейронных сетей с активным тестированием посредством конечно-автоматного агента. Методика подкреплена воспроизводимым программным прототипом и экспериментально проверена на реальном датасете UNSW-NB15 с cross-evaluation на CICIDS2017.

По сравнению с лидером среди классических подходов (XGBoost, $F1 = 0,965$) целевая модель обеспечивает в одиннадцать раз меньшее число ложных срабатываний на типовом потоке корпоративного SOC за счет существенно более низкого FPR на операционном пороге (0,0095 против 0,108). Это формирует фундаментальный практический аргумент в пользу CNN-LSTM как proposed-модели для производственного развертывания в составе подсистемы NTA-аналитики корпоративного SOC.

Разработанная методика обнаружения аномальной активности и несанкционированных действий в корпоративной сети. По итогам работы сформирована методика, представляющая собой последовательность взаимосвязанных процедур и формализованных правил, обеспечивающих воспроизводимое обнаружение аномальной активности в потоковом сетевом трафике. Методика состоит из десяти шагов.

- 1) Сбор и валидация входной телеметрии. На вход системы поступают потоковые записи (flow) в формате CSV, NetFlow v9 или IPFIX. Каждая запись валидируется по Pydantic-схеме на соответствие типам и диапазонам признаков; некорректные строки отбрасываются с логированием.
- 2) Очистка и нормализация. Применяются: унификация регистра и пробелов в категориальных полях; устранение дубликатов; обрезка хвостов

распределений по квантилям 0,001 и 0,999; лог-преобразование тяжелостных числовых признаков; робастное масштабирование (медиана, IQR). Все статистики собираются только на обучающей выборке.

- 3) Кодирование категориальных признаков. Применяется one-hot кодирование для признаков малой кардинальности (`proto`, `state`) и frequency-кодирование для `service`. Неизвестные категории получают значение `unknown` с нулевой частотой.
- 4) Формирование скользящих окон. Из последовательности flow-записей формируются окна длины $W = 32$ с шагом $S = 8$ (75 % перекрытие); метка окна определяется по последней записи (last-агрегация).
- 5) Нейросетевой инференс. Каждое окно подается на вход обученной модели CNN-LSTM (двунаправленный LSTM, attention-пулинг, LayerNorm), которая возвращает вероятность атаки $p \in [0, 1]$ для всего окна.
- 6) Калибровка вероятностей и порога. Применяется температурное масштабирование логитов с параметром T , подобранным на валидационной выборке через L-BFGS; операционный порог τ определяется бинарным поиском по отсортированному списку скорингов нормальных окон под целевую частоту ложных срабатываний $FPR^* = 0,01$.
- 7) Принятие решения. Для каждого окна выносится бинарное решение $\hat{y} = \mathbb{I}[p \geq \tau]$.
- 8) Формирование алертов. Каждое положительное решение обрабатывается алертформером, который присваивает уровень критичности по пятиступенчатой шкале (`info`, `low`, `medium`, `high`, `critical`) на основе нормированного превышения скоринга над порогом, и выполняет временную дедупликацию повторов по триплету (`src_ip`, `dst_ip`, `attack_cat`) в окне 5 с.
- 9) Мониторинг дрейфа распределений. Параллельно с инференсом подсистема `drift_report` вычисляет индексы PSI, KL и MMD² между текущим окном и эталонной обучающей выборкой; при превышении порога $PSI > 0,25$ устанавливается индикатор `drift_alarm`, направляемый в SOC как событие дрейфа.
- 10) Активное тестирование. На стенде проводится воспроизводимое стресс-тестирование детектора с использованием конечно-автоматного

агента, имеющего 11 состояний (NORMAL, 7 ATTACK, 3 DRIFT), стохастическую матрицу переходов, минимальные длительности состояний, библиотеку из семи параметризованных шаблонов атак и инжектор дрейфа трех типов. По прогону рассчитываются per-state recall, F1 и FPR.

- 11) Экспорт и интеграция. Алерты выгружаются в JSON Lines формате, совместимом с типовыми SIEM, а также доступны через REST API (GET /alerts/recent) и визуальную панель Streamlit, привязанную к сервису по DIPLOMA_API_URL.

Сформированная методика обеспечивает повторяемость результатов обнаружения на одних и тех же входных данных (побитовая воспроизводимость при фиксированных seed-ax), независимость от конкретного источника телеметрии (поддерживаются NetFlow v9 и IPFIX без модификации кода), прозрачную процедуру калибровки порога под локальный эксплуатационный FPR и встроенный механизм сигнализации о дрейфе распределений.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Survey of Intrusion Detection Systems: Techniques, Datasets and Challenges / A. Khraisat, I. Gondal, P. Vamplew, J. Kamruzzaman // Cybersecurity. — 2019. — Т. 2. — С. 20. — URL: <https://doi.org/10.1186/s42400-019-0038-7> (дата обр. 13.05.2026).
2. Network Intrusion Detection System: A Systematic Study of Machine Learning and Deep Learning Approaches / Z. Ahmad [и др.] // Transactions on Emerging Telecommunications Technologies. — 2021. — Т. 32, № 1. — e4150. — URL: <https://doi.org/10.1002/ett.4150> (дата обр. 13.05.2026).
3. Sommer R., Paxson V. Outside the Closed World: On Using Machine Learning for Network Intrusion Detection // IEEE Symposium on Security and Privacy. — 2010. — С. 305—316. — URL: <https://doi.org/10.1109/SP.2010.25> (дата обр. 13.05.2026).
4. SMOTE: Synthetic Minority Over-sampling Technique / N. V. Chawla, K. W. Bowyer, L. O. Hall, W. P. Kegelmeyer // Journal of Artificial Intelligence Research. — 2002. — Т. 16. — С. 321—357. — URL: <https://doi.org/10.1613/jair.953> (дата обр. 13.05.2026).
5. Focal Loss for Dense Object Detection / T.-Y. Lin [и др.] // IEEE International Conference on Computer Vision (ICCV). — 2017. — С. 2980—2988. — URL: <https://doi.org/10.1109/ICCV.2017.324> (дата обр. 13.05.2026).
6. A Survey on Concept Drift Adaptation / J. Gama [и др.] // ACM Computing Surveys. — 2014. — Т. 46, № 4. — 44:1—44:37. — URL: <https://doi.org/10.1145/2523813> (дата обр. 13.05.2026).
7. INSOMNIA: Towards Concept-Drift Robustness in Network Intrusion Detection / G. Andresini [и др.] // 14th ACM Workshop on Artificial Intelligence and Security (AISec). — 2021. — С. 111—122. — URL: <https://doi.org/10.1145/3474369.3486864> (дата обр. 13.05.2026).

8. Moustafa N., Slay J. UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems (UNSW-NB15 Network Data Set) // Military Communications and Information Systems Conference (MilCIS). — IEEE, 2015. — С. 1—6. — URL: <https://doi.org/10.1109/MilCIS.2015.7348942> (дата обр. 13.05.2026).
9. Sharafaldin I., Lashkari A. H., Ghorbani A. A. Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization // 4th International Conference on Information Systems Security and Privacy (ICISSP). — 2018. — С. 108—116. — URL: <https://doi.org/10.5220/0006639801080116> (дата обр. 13.05.2026).
10. Deep Learning for Cyber Security Intrusion Detection: Approaches, Datasets, and Comparative Study / M. A. Ferrag, L. Maglaras, S. Moschoyiannis, H. Janicke // Journal of Information Security and Applications. — 2020. — Т. 50. — С. 102419. — URL: <https://doi.org/10.1016/j.jisa.2019.102419> (дата обр. 13.05.2026).
11. Claise B. Cisco Systems NetFlow Services Export Version 9 / IETF. — 2004. — URL: <https://www.rfc-editor.org/rfc/rfc3954> (дата обр. 13.05.2026).
12. Claise B., Trammell B., Aitken P. Specification of the IP Flow Information Export (IPFIX) Protocol for the Exchange of Flow Information / IETF. — 2013. — URL: <https://www.rfc-editor.org/rfc/rfc7011> (дата обр. 13.05.2026).
13. Liu F. T., Ting K. M., Zhou Z.-H. Isolation Forest // IEEE International Conference on Data Mining (ICDM). — 2008. — С. 413—422. — URL: <https://doi.org/10.1109/ICDM.2008.17> (дата обр. 13.05.2026).
14. Estimating the Support of a High-Dimensional Distribution / B. Schölkopf [и др.] // Neural Computation. — 2001. — Т. 13, № 7. — С. 1443—1471. — URL: <https://doi.org/10.1162/089976601750264965> (дата обр. 13.05.2026).
15. Deep Learning Approach for Intelligent Intrusion Detection System / R. Vinayakumar [и др.] // IEEE Access. — 2019. — Т. 7. — С. 41525—41550. — URL: <https://doi.org/10.1109/ACCESS.2019.2895334> (дата обр. 13.05.2026).

16. Hochreiter S., Schmidhuber J. Long Short-Term Memory // Neural Computation. — 1997. — Т. 9, № 8. — С. 1735—1780. — URL: <https://doi.org/10.1162/neco.1997.9.8.1735> (дата обр. 13.05.2026).
17. Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation / K. Cho, B. van Merriënboer, C. Gulcehre [и др.] // Conference on Empirical Methods in Natural Language Processing (EMNLP). — 2014. — С. 1724—1734. — URL: <https://doi.org/10.3115/v1/D14-1179> (дата обр. 13.05.2026).
18. Bai S., Kolter J. Z., Koltun V. An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. — 2018. — arXiv: 1803.01271 [cs.LG].
19. Attention Is All You Need / A. Vaswani, N. Shazeer, N. Parmar [и др.] // Advances in Neural Information Processing Systems (NeurIPS). Т. 30. — 2017.
20. Kingma D. P., Welling M. Auto-Encoding Variational Bayes // International Conference on Learning Representations (ICLR). — 2014.
21. An Evaluation Framework for Intrusion Detection Dataset / A. Gharib, I. Sharafaldin, A. H. Lashkari, A. A. Ghorbani // International Conference on Information Science and Security (ICISA). — IEEE, 2016. — С. 1—6. — URL: <https://doi.org/10.1109/ICISSEC.2016.7885840> (дата обр. 13.05.2026).
22. The 1999 DARPA Off-line Intrusion Detection Evaluation / R. P. Lippmann, D. J. Fried, I. Graf [и др.] // Computer Networks. — 2000. — Т. 34, № 4. — С. 579—595. — URL: [https://doi.org/10.1016/S1389-1286\(00\)00139-0](https://doi.org/10.1016/S1389-1286(00)00139-0) (дата обр. 13.05.2026).
23. A Detailed Analysis of the KDD CUP 99 Data Set / M. Tavallaee, E. Bagheri, W. Lu, A. A. Ghorbani // IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA). — IEEE, 2009. — С. 1—6. — URL: <https://doi.org/10.1109/CISDA.2009.5356528> (дата обр. 13.05.2026).

24. Moustafa N. A New Distributed Architecture for Evaluating AI-based Security Systems at the Edge: Network TON_IoT Datasets // Sustainable Cities and Society. — 2021. — Т. 72. — С. 102994. — URL: <https://doi.org/10.1016/j.scs.2021.102994> (дата обр. 13.05.2026).
25. Towards the Development of Realistic Botnet Dataset in the Internet of Things for Network Forensic Analytics: Bot-IoT Dataset / N. Koroniotis, N. Moustafa, E. Sitnikova, B. Turnbull // Future Generation Computer Systems. — 2019. — Т. 100. — С. 779—796. — URL: <https://doi.org/10.1016/j.future.2019.05.041> (дата обр. 13.05.2026).
26. Statistical Analysis of Honeypot Data and Building of Kyoto 2006+ Dataset for NIDS Evaluation / J. Song [и др.] // 1st Workshop on Building Analysis Datasets and Gathering Experience Returns for Security (BADGERS). — 2011. — С. 29—36. — URL: <https://doi.org/10.1145/1978672.1978676> (дата обр. 13.05.2026).
27. LITNET-2020: An Annotated Real-World Network Flow Dataset for Network Intrusion Detection / R. Damasevicius, A. Venckauskas, S. Grigaliunas [и др.] // Electronics. — 2020. — Т. 9, № 5. — С. 800. — URL: <https://doi.org/10.3390/electronics9050800> (дата обр. 13.05.2026).
28. Flow-based Network Traffic Generation Using Generative Adversarial Networks / M. Ring, D. Schlör, D. Landes, A. Hotho // Computers & Security. — 2019. — Т. 82. — С. 156—172. — URL: <https://doi.org/10.1016/j.cose.2018.12.012> (дата обр. 13.05.2026).
29. Conditional Variational Autoencoder for Prediction and Feature Recovery Applied to Intrusion Detection in IoT / M. Lopez-Martin, B. Carro, A. Sanchez-Esguevillas, J. Lloret // Sensors. — 2017. — Т. 17, № 9. — С. 1967. — URL: <https://doi.org/10.3390/s17091967> (дата обр. 13.05.2026).
30. Generative Adversarial Nets / I. Goodfellow, J. Pouget-Abadie, M. Mirza [и др.] // Advances in Neural Information Processing Systems (NeurIPS). Т. 27. — 2014.
31. Mirza M., Osindero S. Conditional Generative Adversarial Nets. — 2014. — arXiv: 1411.1784 [cs.LG].

32. Arjovsky M., Chintala S., Bottou L. Wasserstein Generative Adversarial Networks // International Conference on Machine Learning (ICML). — 2017. — С. 214—223.
33. Improved Training of Wasserstein GANs / I. Gulrajani [и др.] // Advances in Neural Information Processing Systems (NeurIPS). Т. 30. — 2017.
34. Deep Reinforcement Adversarial Learning Against Network Intrusion Detection in Continuous-Time / G. Apruzzese [и др.] // IEEE Transactions on Network and Service Management. — 2020. — Т. 17, № 4. — С. 1975—1987. — URL: <https://doi.org/10.1109/TNSM.2020.3031843> (дата обр. 13.05.2026).
35. On Calibration of Modern Neural Networks / C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger // International Conference on Machine Learning (ICML). — 2017. — С. 1321—1330.
36. Moustafa N., Slay J. The Evaluation of Network Anomaly Detection Systems: Statistical Analysis of the UNSW-NB15 Data Set and the Comparison with the KDD99 Data Set // Information Security Journal: A Global Perspective. — 2016. — Т. 25, № 1—3. — С. 18—31. — URL: <https://doi.org/10.1080/19393555.2015.1125974> (дата обр. 13.05.2026).
37. Chen T., Guestrin C. XGBoost: A Scalable Tree Boosting System // ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. — 2016. — С. 785—794. — URL: <https://doi.org/10.1145/2939672.2939785> (дата обр. 13.05.2026).

ПРИЛОЖЕНИЕ А

(справочное)

Полная таблица результатов эксперимента E1

В таблице А.1 приведена полная сводка результатов эксперимента E1 на UNSW-NB15 для всех 15 моделей-кандидатов (23 запуска: для CNN-LSTM, XGBoost, Random Forest, Logistic Regression — по три seed, для остальных моделей — один seed). Для каждой модели зафиксированы: число seed, F1-max, 95 % bootstrap-CI для F1-max, PR-AUC, ROC-AUC, MCC, операционные F1 и FPR на пороге под target-FPR = 0,01 на валидации, inference latency на одно окно.

Таблица А.1 — Полная сводка результатов эксперимента E1 (15 моделей, 23 запуска)

Модель	s	F1max	CI low	CI hi	PR-AUC	ROC-AUC	MCC	Op. F1	Op. FPR	Lat.
cnn_lstm	3	0,974	0,971	0,976	0,995	0,992	0,918	0,971	0,010	1,16
xgboost	3	0,965	0,963	0,967	0,993	0,987	0,889	0,965	0,108	0,41
random_forest	3	0,962	0,960	0,965	0,992	0,985	0,879	0,960	0,105	42,7
gru	1	0,960	0,958	0,963	0,989	0,979	0,873	0,935	0,055	1,47
mlp	1	0,955	0,953	0,957	0,988	0,977	0,855	0,914	0,057	0,25
transformer	1	0,954	0,952	0,957	0,983	0,968	0,852	0,874	0,057	0,88
bilstm	1	0,952	0,949	0,954	0,987	0,975	0,848	0,885	0,043	0,78
tcn	1	0,951	0,948	0,953	0,982	0,971	0,844	0,852	0,035	1,70
logistic_regression	3	0,951	0,948	0,954	0,973	0,952	0,846	0,948	0,084	0,18
lstm	1	0,948	0,946	0,951	0,988	0,974	0,840	0,932	0,054	0,43
cnn1d	1	0,936	0,933	0,939	0,976	0,957	0,797	0,879	0,044	0,45
isolation_forest	1	0,922	0,919	0,924	0,953	0,920	0,738	0,584	0,017	15,7
ocsvm	1	0,866	0,862	0,871	0,892	0,831	0,549	0,609	0,097	2,20
vae	1	0,811	0,807	0,815	0,612	0,430	0,060	0,000	0,000	0,62
autoencoder	1	0,811	0,806	0,815	0,614	0,437	0,053	0,000	0,000	0,69

Обозначения: «s» — число seed-ов; «F1max» — F1 при оптимальном пороге на test; «CI low / hi» — границы 95 % bootstrap-доверительного интервала для F1-max (200 ресэмпллов); «Op. F1» и «Op. FPR» — метрики на операционном пороге под target-FPR = 0,01 на валидации; «Lat.» — inference latency на одно окно, мс (CPU, batch = 1, медианное значение по 50 прогонам после

прогрева). Полная таблица результатов в формате CSV (E1_summary.csv) поставляется в составе артефактов программного прототипа.

ПРИЛОЖЕНИЕ Б

(справочное)

Структура программного прототипа и команды запуска

Прототип реализован как Python-пакет `diploma_nids` с подпакетами `data`, `models`, `training`, `eval`, `attacker`, `inference`, `ui`, `utils`. Полное описание модулей и тестов приведено на этапе 3 настоящего отчета.

Запуск экспериментов (из корневой директории программного прототипа):

```
make install-dev
python scripts/02_build_dataset.py \
    --config configs/data/unsw_nb15.yaml \
    --preprocess configs/preprocess/default.yaml \
    --strategy official
python scripts/10_run_experiment_E1.py \
    --train configs/train/full.yaml --seeds 42 123 2024
python scripts/11_run_experiment_E2_error_analysis.py
python scripts/12_run_experiment_E4_attacker.py
python scripts/13_run_experiment_E5_drift.py
python scripts/20_build_thesis_tables.py
python scripts/22_parse_training_logs.py
python scripts/21_plot_training_history.py
python scripts/30_demo_run.py
```

ПРИЛОЖЕНИЕ В

(справочное)

Конфигурации экспериментов

Все стадии pipeline параметризуются YAML-файлами в каталоге `configs/` программного прототипа. Ключевые группы конфигов:

- `configs/data/` — схемы UNSW-NB15 и CICIDS2017 (mapping общих признаков для cross-evaluation);
- `configs/preprocess/default.yaml` — параметры очистки, encoding, log/robust scaling, windowing, splits, балансировки;
- `configs/models/` — архитектуры 10 DL-моделей (`cnn_lstm.yaml` — proposed) и параметры 5 классических моделей (`classical.yaml`);
- `configs/train/` — параметры обучения (`full.yaml` для полного режима, `smoke.yaml` для smoke-тестов);
- `configs/eval/default.yaml` — метрики, калибровка, bootstrap CI, drift-monitoring;
- `configs/attacker/` — политика FSM (`policy.yaml`), 7 шаблонов атак, drift-инжектор (`drift.yaml`);
- `configs/pipeline/realtime.yaml` — конфигурация realtime-стенда FastAPI + Streamlit + agent.

Каждый запуск экспериментов фиксирует: версию кода (commit hash), набор seed, гиперпараметры, версии зависимостей, полное содержимое использованных конфигов в виде attached-артефактов.