



Федеральное государственное автономное образовательное учреждение
высшего образования «Национальный исследовательский ядерный
университет «МИФИ»

Кафедра №42 «Криптология и кибербезопасность»

**МЕТОДИКА ОБНАРУЖЕНИЯ НЕСАНКЦИОНИРОВАННЫХ
ДЕЙСТВИЙ И АНОМАЛЬНОЙ АКТИВНОСТИ В
КОРПОРАТИВНОЙ СЕТИ С ИСПОЛЬЗОВАНИЕМ НЕЙРОННЫХ
СЕТЕЙ**

Выпускная квалификационная работа

10.03.01 Информационная безопасность

Автор:

Титов Дмитрий Иванович

Научный руководитель:

Когос Константин Григорьевич, кандидат технических наук

Консультант:

Ланской Даниил Петрович

Москва 2026г.

АКТУАЛЬНОСТЬ ИССЛЕДОВАНИЯ

Внедрение средств обнаружения и предотвращения вторжений в составе значимых объектов критической информационной инфраструктуры прямо предписано Федеральным законом № 187-ФЗ от 26.07.2017 [1], приказом ФСТЭК России № 239 в редакции 28.08.2024 [2], Указом Президента РФ № 250 от 01.05.2022 [3] и Доктриной информационной безопасности РФ [4].

Прирост числа DDoS-атак на российскую инфраструктуру за 2025 год составил +42 % по данным Kaspersky DDoS Protection [5]; Solar JSOC фиксирует рост общего числа инцидентов на +27 % за I полугодие 2025 года к 2024-му [6]; по данным Positive Technologies наблюдается смещение векторов атак с сетевого уровня (L3/L4) на прикладной (L7) [7]; НКЦКИ отмечает увеличение доли таргетированных атак на критическую инфраструктуру [8].

Доля зашифрованного трафика в корпоративных сетях превышает 90 %, что ограничивает применимость классического сигнатурного анализа и переносит центр тяжести разработки NIDS на flow-уровневый анализ метаданных потоков (NetFlow [9], IPFIX [10]).

1. О безопасности критической информационной инфраструктуры Российской Федерации : Федер. закон от 26.07.2017 № 187-ФЗ // КонсультантПлюс : справ.-правовая система. URL: http://www.consultant.ru/document/cons_doc_LAW_220885/ (дата обращения: 22.05.2026).
2. Об утверждении Требований по обеспечению безопасности значимых объектов критической информационной инфраструктуры Российской Федерации : приказ ФСТЭК России от 25.12.2017 № 239 (в ред. от 28.08.2024) // ФСТЭК России : офиц. сайт. URL: <https://fstec.ru/> (дата обращения: 22.05.2026).
3. О дополнительных мерах по обеспечению информационной безопасности Российской Федерации : Указ Президента РФ от 01.05.2022 № 250 // Президент России : офиц. сайт. URL: <http://www.kremlin.ru/> (дата обращения: 22.05.2026).
4. Доктрина информационной безопасности Российской Федерации : утв. Указом Президента РФ от 05.12.2016 № 646. М., 2016.
5. Kaspersky DDoS Attacks Report 2025 : аналит. отчет / Kaspersky Lab. URL: <https://securelist.com/ddos-report-2025/> (дата обращения: 22.05.2026).
6. Solar JSOC Security Report 2025 : аналит. отчет / ГК <<PTK-Solar>>. М., 2025. URL: <https://rt-solar.ru/analytics/> (дата обращения: 22.05.2026).
7. Актуальные киберугрозы 2025 : аналит. отчет / Positive Technologies. М., 2025. URL: <https://www.ptsecurity.com/ru-ru/research/analytics/> (дата обращения: 22.05.2026).
8. Бюллетень НКЦКИ за 2025 год / Национальный координационный центр по компьютерным инцидентам. URL: <https://safe-surf.ru/> (дата обращения: 22.05.2026).
9. Claise B. Cisco Systems NetFlow Services Export Version 9 : RFC 3954 / B. Claise ; IETF. 2004. 33 p.
10. Specification of the IP Flow Information Export (IPFIX) Protocol for the Exchange of Flow Information : RFC 7011 / B. Claise, B. Trammell, P. Aitken ; IETF. 2013. 76 p.

ЦЕЛЬ И ЗАДАЧИ ИССЛЕДОВАНИЯ

Цель работы – разработка методики нейросетевого обнаружения несанкционированных действий и аномальной активности в корпоративной сети, валидируемой конечно-автоматным агентом активного тестирования с библиотекой параметризованных шаблонов атак.

Задачи:

- Аналитический обзор предметной области обнаружения аномалий в сетях
- Формализация функциональных и нефункциональных требований
- Проектирование методики и архитектуры нейросетевого детектора
- Разработка подсистемы предобработки и формирования выборок
- Реализация и обучение нейросетевых моделей в едином регистре
- Разработка конечно-автоматного агента активного тестирования
- Реализация программного прототипа в реальном времени
- Экспериментальная проверка эффективности методики (Е1-Е6)
- Оценка эксплуатационных характеристик и оформление материалов

ОБЪЕКТ И ПРЕДМЕТ ИССЛЕДОВАНИЯ

- Объект исследования: Методы и технологии обнаружения аномальной активности и несанкционированных действий в корпоративных сетях на основе данных мониторинга, прежде всего телеметрии сетевого трафика. Данные о поведении пользователей рассматриваются в теоретической части как один из возможных источников, в экспериментальной реализации и валидации не используются.
- Предмет исследования: Применение нейросетевых методов для выявления аномалий и признаков несанкционированной активности по данным сетевого трафика, а также разработка и применение программного агента на основе конечного автомата и библиотеки параметризованных атакующих шаблонов для синтеза трафика и сценариев активного тестирования и валидации системы обнаружения.

МЕТОДОЛОГИЯ И МЕТОДЫ ИССЛЕДОВАНИЯ

- Системный анализ предметной области и сравнительный обзор подходов NIDS/NTA по рецензируемым публикациям и нормативным документам РФ
- Балльная оценка нейросетевых архитектур и публично доступных датасетов NIDS по литературно обоснованным критериям с весами
- Формализация функциональных и нефункциональных требований и количественных критериев качества
- Обучение нейросетевых и классических моделей в идентичных условиях; ensemble-усреднение вероятностей по нескольким seed для CNN-LSTM
- Калибровка вероятностей через температурное масштабирование (Guo et al. 2017) и порог под целевой FPR=0.01
- Стресс-тестирование детектора посредством программного агента на основе конечного автомата с библиотекой параметризованных шаблонов и инжектором дрейфа (PSI/KL/MMD)
- Статистический анализ: bootstrap-доверительные интервалы 95%, парный непараметрический критерий Уилкоксона при сравнении моделей
- Инженерные методы: модульное проектирование, YAML-конфигурация, юнит-тестирование критических инвариантов pipeline

ГИПОТЕЗА

Методика обнаружения, использующая нейросетевую обработку последовательностей flow-признаков в скользящих окнах и валидируемая конечно-автоматным агентом с контролируемым инжектированием дрейфа распределений, превосходит классические сигнатурные и статистические подходы NIDS по комплексному критерию качества (точность, полнота, FPR при заданной полноте, задержка детекции, устойчивость к дрейфу).

БАЛЛЬНАЯ ОЦЕНКА НЕЙРОСЕТЕВЫХ АРХИТЕКТУР

Таблица 1 - Взвешенная сравнительная оценка девяти нейросетевых архитектур по семи критериям

Архитектура	Моделирование локальных паттернов (0,15)	Моделирование временных зависимостей (0,20)	F1/Ассурасу в рецензируемых работах на современных датасетах NIDS(0,25)	Сложность обучения (0,05)	Inference latency на CPU(0,15)	Число независимых воспроизведений (0,10)	Гибкость расширения (0,10)	Балл
MLP [4]	1	1	2	5	5	2	2	2,15
1D-CNN [3]	4	2	3	4	5	3	3	3,3
LSTM [5]	1	4	3	3	4	4	3	3,15
GRU [2]	1	4	3	4	4	4	3	3,2
BiLSTM [2]	2	5	4	2	3	4	3	3,55
TCN [6]	4	4	3	3	3	3	3	3,4
CNN-LSTM [4, 7]	5	5	5	2	4	5	5	4,6
Transformer-encoder [8]	3	4	4	2	3	3	4	3,45
AE / VAE [9]	2	1	2	3	4	3	3	2,4

1. Khraisat A. Survey of intrusion detection systems: techniques, datasets and challenges / A. Khraisat, I. Gondal, P. Vamplew, J. Kamruzzaman // *Cybersecurity*. 2019. Vol. 2, № 1. P. 1-22.
2. Ahmad Z. Network intrusion detection system: A systematic study of machine learning and deep learning approaches / Z. Ahmad, A. Shahid Khan, C. Wai Shiang, J. Abdullah, F. Ahmad // *Transactions on Emerging Telecommunications Technologies*. 2021. Vol. 32, № 1. P. e4150.
3. Ferrag M. A. Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study / M. A. Ferrag [et al.] // *Journal of Information Security and Applications*. 2020. Vol. 50. P. 102419.
4. Vinayakumar R. Deep learning approach for intelligent intrusion detection system / R. Vinayakumar [et al.] // *IEEE Access*. 2019. Vol. 7. P. 41525-41550.
5. Hochreiter S. Long Short-Term Memory / S. Hochreiter, J. Schmidhuber // *Neural Computation*. 1997. Vol. 9, № 8. P. 1735-1780.
6. Bai S. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling / S. Bai, J. Z. Kolter, V. Koltun. *arXiv:1803.01271*. 2018.
7. Enhanced network intrusion detection using a hybrid CNN-LSTM approach on UNSW-NB15 // *IEEE Transactions*. 2024.
8. Vaswani A. Attention is all you need / A. Vaswani [et al.] // *Advances in Neural Information Processing Systems (NeurIPS)*. 2017. P. 5998-6008.
9. Kingma D. P. Auto-encoding variational Bayes / D. P. Kingma, M. Welling // *Int. Conf. on Learning Representations (ICLR)*. 2014.

БАЛЛЬНАЯ ОЦЕНКА ДАТАСЕТОВ NIDS

Таблица 2 - Взвешенная сравнительная оценка десяти публично доступных датасетов NIDS по восьми критериям

Датасет	Актуальность модели угроз (0,15)	Репрезентативность нормального трафика (0,15)	Качество разметки (0,15)	Сбалансированность распределения классов (0,10)	Пригодность для глубокого обучения (0,15)	Flow-формат и совместимость с NetFlow/IPFIX (0,10)	Воспроизводимость (0,10)	Активность использования в современной литературе (0,10)	Балл
DARPA 1998/1999	1	2	3	3	1	2	4	1	2,1
KDDCup99	1	1	2	3	3	2	4	2	2,05
NSL-KDD	1	2	3	4	2	2	5	4	2,7
UNSW-NB15 [4]	5	5	5	4	5	5	5	5	4,8
CICIDS2017 [5, 3]	4	4	2	3	4	5	4	5	3,75
CSE-CIC-IDS2018	4	4	2	3	4	5	3	4	3,5
TON-IoT	4	3	4	3	4	5	4	4	3,75
Bot-IoT	3	1	4	1	4	5	4	3	3,05
Kyoto 2006+	2	2	3	3	3	3	3	2	2,55
LITNET-2020	4	4	3	3	4	4	3	3	3,5

1. Gharib A. An evaluation framework for intrusion detection dataset / A. Gharib, I. Sharafaldin, A. H. Lashkari, A. A. Ghorbani // Proc. IEEE Int. Conf. on Information Science and Security (ICISS). 2016.
2. Ring M. A survey of network-based intrusion detection data sets / M. Ring, S. Wunderlich, D. Scheuring, D. Landes, A. Hotho // Computers & Security. 2019. Vol. 86. P. 147-167.
3. Engelen G. Troubleshooting an intrusion detection dataset: the CICIDS2017 case study / G. Engelen, V. Rimmer, W. Joosen // Proc. IEEE Security and Privacy Workshops (SPW). 2021. P. 7-12.
4. Moustafa N. UNSW-NB15: A comprehensive data set for network intrusion detection systems / N. Moustafa, J. Slay // Proc. IEEE Military Communications and Information Systems Conf. (MilCIS). 2015. P. 1-6.
5. Sharafaldin I. Toward generating a new intrusion detection dataset and intrusion traffic characterization / I. Sharafaldin, A. Habibi Lashkari, A. A. Ghorbani // Proc. 4th Int. Conf. on Information Systems Security and Privacy (ICISSP). 2018. P. 108-116.

ФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ

Таблица 3 - Перечень функциональных требований к системе

Группа	Шифр	Содержание требования
I. Данные и подготовка	FR-1	Загрузка и валидация телеметрии (Pydantic-схема, CSV flow UNSW-NB15 / CICIDS2017) [1]
	FR-2	Предобработка: cleanup, one-hot / freq-encoding, log1p + robust scaling, окна $W = 32$, $S = 8$ [2, 3]
II. Модель и принятие решения	FR-3	Единый регистр 15 моделей-кандидатов (10 DL + 5 classical), общий интерфейс [4, 2]
	FR-4	Калибровка вероятностей (T-scaling, L-BFGS) и порога τ под целевой эксплуатационный FPR [5]
III. Интерфейсы и алертинг	FR-5	Формирование алертов: 5-уровневая severity + временная дедупликация по (src, dst, attack_cat) [6]
	FR-6	REST-API инференса: /score, /score-window, /alerts/recent (FastAPI)
	FR-7	Визуальная панель Streamlit: дэшборд алертов, временной ряд скорингов, метрики
IV. Тестирование и эксплуатация	FR-8	Активное тестирование: FSM-агент + 7 шаблонов атак + инжектор дрейфа (covariate / prior / concept) [7]
	FR-9	Мониторинг дрейфа распределений: PSI / KL / MMD ² + индикатор drift_alarm [7]
	FR-10	Воспроизводимость: seed-фиксация, YAML-конфиги, JSON-журналы прогонов

1. Moustafa N. UNSW-NB15: A comprehensive data set for network intrusion detection systems / N. Moustafa, J. Slay // Proc. IEEE Military Communications and Information Systems Conf. (MilCIS). 2015. P. 1-6.
2. Ahmad Z. Network intrusion detection system: A systematic study of machine learning and deep learning approaches / Z. Ahmad, A. Shahid Khan, C. Wai Shiang, J. Abdullah, F. Ahmad // Transactions on Emerging Telecommunications Technologies. 2021. Vol. 32, № 1. P. e4150.
3. Ferrag M. A. Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study / M. A. Ferrag [et al.] // Journal of Information Security and Applications. 2020. Vol. 50. P. 102419.
4. Khraisat A. Survey of intrusion detection systems: techniques, datasets and challenges / A. Khraisat, I. Gondal, P. Vamplew, J. Kamruzzaman // Cybersecurity. 2019. Vol. 2, № 1. P. 1-22.
5. Guo C. On calibration of modern neural networks / C. Guo [et al.] // Proc. Int. Conf. on Machine Learning (ICML). 2017. P. 1321-1330.
6. Vinayakumar R. Deep learning approach for intelligent intrusion detection system / R. Vinayakumar [et al.] // IEEE Access. 2019. Vol. 7. P. 41525-41550.
7. Gama J. A survey on concept drift adaptation / J. Gama [et al.] // ACM Computing Surveys. 2014. Vol. 46, № 4. P. 44:1-44:37.

НЕФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ

Таблица 4 - Перечень нефункциональных требований с числовыми порогами

Группа	Шифр	Содержание требования
I. Качество детекции	NFR-1a	$F1 \text{ на UNSW-NB15} \geq 0,90$ [1, 2]
	NFR-1b	$PR-AUC \text{ на UNSW-NB15} \geq 0,95$ [1]
	NFR-2	$FPR \leq 0,01$ при $Recall \geq 0,85$ [3]
II. Эксплуатационная производительность	NFR-3	Inference latency ≤ 50 мс / окно (CPU, batch = 1) [1]
	NFR-4	Throughput ≥ 1000 EPS (CPU, батч-режим) [1]
	NFR-5	Time-to-detect ≤ 1 окно (DDoS / Scan / Brute force)
III. Устойчивость к дрейфу и переносимость	NFR-6	$\Delta F1 \leq 0,10$ при $PSI \leq 0,25$ (контролируемый дрейф) [4]
	NFR-7	$\Delta F1 \leq 0,20$ при cross-eval UNSW-NB15 $\rightarrow$ CICIDS2017 [5, 6]
IV. Воспроизводимость и стабильность	NFR-8	Полный прогон одной командой (make reproduce)
	NFR-9	$\sigma F1 \leq 0,01$ по $n \geq 3$ независимым seed

1. Vinayakumar R. Deep learning approach for intelligent intrusion detection system / R. Vinayakumar [et al.] // IEEE Access. 2019. Vol. 7. P. 41525-41550.
2. Moustafa N. UNSW-NB15: A comprehensive data set for network intrusion detection systems / N. Moustafa, J. Slay // Proc. IEEE Military Communications and Information Systems Conf. (MilCIS). 2015. P. 1-6.
3. Guo C. On calibration of modern neural networks / C. Guo [et al.] // Proc. Int. Conf. on Machine Learning (ICML). 2017. P. 1321-1330.
4. Gama J. A survey on concept drift adaptation / J. Gama [et al.] // ACM Computing Surveys. 2014. Vol. 46, № 4. P. 44:1-44:37.
5. Engelen G. Troubleshooting an intrusion detection dataset: the CICIDS2017 case study / G. Engelen, V. Rimmer, W. Joosen // Proc. IEEE Security and Privacy Workshops (SPW). 2021. P. 7-12.
6. Farooq M. A detailed analysis of benchmark datasets for network intrusion detection system / M. Farooq [et al.]. arXiv:2403.17458. 2024

ОБЩАЯ АРХИТЕКТУРА И ПОДСИСТЕМЫ





Рисунок 1 - Общая архитектура методики обнаружения: BPMN-схема потоков данных с параллельными ветвями мониторинга дрейфа и активного тестирования

Условные обозначения BPMN: ● — событие (start / end), □ — задача (подсистема), ◇ (+) — параллельный шлюз (fork / join), → — поток данных / управления.
Цвет дорожек: синий — основная цепочка обнаружения; зелёный — мониторинг дрейфа распределений; оранжевый — активное тестирование FSM-агентом (только на стенде).

Пайплайн обработки одного окна: flow-записи → схема → cleanup → encoding → scaling → окно $W \times F$ → модель → калибровка $\hat{p}$ → порог τ → алерт (severity, dedup) → JSONL / REST.

ЦЕЛЕВАЯ АРХИТЕКТУРА CNN-LSTM

I. Нейросетевой признаковый блок (CNN-LSTM)



II. Калибровка вероятностей и принятие решения




Рисунок 2 - Двухдорожечная блочная диаграмма детектора CNN-LSTM: дорожка I - извлечение признаков нейросетью; дорожка II - калибровка вероятностей и принятие решения

КОНЕЧНО-АВТОМАТНЫЙ АГЕНТ АКТИВНОГО ТЕСТИРОВАНИЯ

11 состояний FSM: NORMAL + 7 ATTACK + 3 DRIFT [1]

Таблица 5 - Библиотека параметризованных шаблонов атак агента

Шаблон	Класс UNSW [2]	Характерные признаки
ddos_synflood	DoS	Высокая скорость, доминирование SYN, малые sbytes
port_scan	Reconnaissance	Малые dur, фан-аут на портах, малый dbytes
brute_force	Reconnaissance / Exploits	Повторяющиеся короткие сессии на одном порту
exploit_payload	Exploits	Большие sbytes, аномальные сочетания TCP-флагов
data_exfil	Backdoors	Длинные сессии, асимметрия b_out/b_in, стабильная скорость
internal_recon	Reconnaissance	Внутренние IP-источники, фан-аут по dst
worm_lateral	Worms	Веерное распространение по портам и хостам

Инжектор дрейфа [1]: covariate (сдвиг масштаба и шума), prior (изменение долей классов), concept (маскирование сигнатурных признаков). Интенсивность alpha в {0; 0,25; 0,5; 0,75; 1,0}.

1. Gama J. A survey on concept drift adaptation / J. Gama [et al.] // ACM Computing Surveys. 2014. Vol. 46, № 4. P. 44:1-44:37.

2. Moustafa N. UNSW-NB15: A comprehensive data set for network intrusion detection systems / N. Moustafa, J. Slay // Proc. IEEE Military Communications and Information Systems Conf. (MilCIS). 2015. P. 1-6.

ТЕХНОЛОГИЧЕСКИЙ СТЕК

Таблица 6 - Сводный технологический стек прототипа

Компонент	Выбор	Ключевой довод выбора
DL-фреймворк	PyTorch 2.x (CPU) [1]	Динамический вычислительный граф; стандарт в публикациях NIDS 2023-2025; CPU-сборка укладывается в NFR-3 (latency 1,16 мс на окно)
Классические модели	scikit-learn 1.x + XGBoost 2.x [2, 3]	scikit-learn - эталонный воспроизводимый ML; XGBoost - лидер по F1 среди gradient-boosting на UNSW-NB15 и CICIDS2017
Unsupervised baselines	Isolation Forest, OC-SVM, AE, VAE [4, 5]	Isolation Forest - эталонный outlier detection; VAE - генеративный baseline; AE - классика anomaly detection в NIDS
Функция потерь	Focal loss (alpha = 0,25, gamma = 2,0) [6]	Снижает влияние easy-negatives на градиент; обоснованно применима при imbalance 13:87 (UNSW-NB15)
Оптимизатор	AdamW + cosine annealing [7]	Корректное weight decay через decoupled regularization; cosine annealing стабильнее ступенчатого LR-decay
Калибровка вероятностей	Temperature scaling (L-BFGS) [8]	Сохраняет ranking AUC; единственная скалярная переменная T; снижение ECE на 67 % в эксперименте E3
Валидация конфигов	Pydantic v2 + PyYAML 6.x	Декларативная типизация с runtime-проверками; экспорт в JSON Schema; минимум boilerplate
REST-сервис	FastAPI + uvicorn	ASGI с async/await; автогенерация OpenAPI; встроенная валидация request/response через Pydantic; низкая latency
UI / дэшборд	Streamlit	Минимум кода для оперативного дэшборда; нативная поддержка pandas и matplotlib; production-ready hot-reload
Тестирование, сборка, лог	pytest 8.x; Make + YAML; logging stdlib + JSONL	86 проходящих юнит-тестов в 11 модулях; YAML-конфиги для каждого эксперимента; JSON Lines-формат под интеграцию с SIEM

1. Paszke A. PyTorch: An imperative style, high-performance deep learning library / A. Paszke [et al.] // *Advances in Neural Information Processing Systems (NeurIPS)*. 2019. P. 8024-8035.
2. Chen T. XGBoost: A scalable tree boosting system / T. Chen, C. Guestrin // *Proc. 22nd ACM SIGKDD Conf. on Knowledge Discovery and Data Mining (KDD)*. 2016. P. 785-794.
3. Pedregosa F. Scikit-learn: Machine learning in Python / F. Pedregosa [et al.] // *Journal of Machine Learning Research*. 2011. Vol. 12. P. 2825-2830.
4. Liu F. T. Isolation forest / F. T. Liu, K. M. Ting, Z.-H. Zhou // *Proc. IEEE Int. Conf. on Data Mining (ICDM)*. 2008. P. 413-422.
5. Kingma D. P. Auto-encoding variational Bayes / D. P. Kingma, M. Welling // *Int. Conf. on Learning Representations (ICLR)*. 2014.
6. Lin T.-Y. Focal loss for dense object detection / T.-Y. Lin [et al.] // *Proc. IEEE Int. Conf. on Computer Vision (ICCV)*. 2017. P. 2980-2988.
7. Loshchilov I. Decoupled weight decay regularization / I. Loshchilov, F. Hutter // *Int. Conf. on Learning Representations (ICLR)*. 2019.
8. Guo C. On calibration of modern neural networks / C. Guo [et al.] // *Proc. Int. Conf. on Machine Learning (ICML)*. 2017. P. 1321-1330.

ЭКСПЕРИМЕНТ Е1. СРАВНЕНИЕ 15 МОДЕЛЕЙ НА UNSW-NB15

Таблица 7 - Сводные метрики качества по результатам эксперимента Е1 (топ-10 моделей)

Модель	s	F1-max	PR-AUC	ROC-AUC	MCC	Op. F1	Op. FPR
CNN-LSTM (proposed)	3	0,9735	0,9945	0,9923	0,918	0,9712	0,0095
XGBoost	3	0,9651	0,9932	0,9870	0,889	0,9650	0,108
Random Forest	3	0,9623	0,9922	0,9853	0,879	0,9603	0,105
GRU	1	0,9601	0,9894	0,9785	0,873	0,9347	0,055
MLP	1	0,9548	0,9878	0,9770	0,855	0,9144	0,057
Transformer	1	0,9543	0,9829	0,9683	0,852	0,8744	0,057
BiLSTM	1	0,9517	0,9868	0,9750	0,848	0,8848	0,043
TCN	1	0,9508	0,9818	0,9708	0,844	0,8519	0,035
Logistic Regression	3	0,9507	0,9732	0,9523	0,846	0,9476	0,084
LSTM	1	0,9483	0,9876	0,9736	0,840	0,9317	0,054

ЭКСПЕРИМЕНТ Е1. РАНЖИРОВАНИЕ МОДЕЛЕЙ ПО F1-MAx

CNN-LSTM лидирует по F1-max (0,9735) среди 15 моделей; проигрывает только по latency и throughput (архитектурное ограничение LSTM на CPU).




Рисунок 3 - Ранжирование моделей на UNSW-NB15 по F1-max

ЭКСПЕРИМЕНТ Е2. АНАЛИЗ ОШИБОК CNN-LSTM




Рисунок 4 - Матрица ошибок




Рисунок 5 - Полнота модели на атаку

На операционном пороге $t = 0,46$: Precision = 0,9954, Recall = 0,948, F1 = 0,9712, FPR = 0,0094. Все 9 классов атак UNSW-NB15 показывают recall $\geq 0,84$; класс Generic --- 1,000.

ЭКСПЕРИМЕНТ ЕЗ. КАЛИБРОВКА ВЕРОЯТНОСТЕЙ И ПОРОГА

Температурное масштабирование: $p_hat = \text{sigmoid}(z / T)$; порог τ калиброван под $\text{target-FPR} = 0,01$ на val .

Таблица 8 - Результаты калибровки вероятностей и порога для восьми DL-моделей

Модель	T	tau	ECE до	ECE после	$\Delta\text{ECE, \%}$	test FPR	test F1
CNN-LSTM	1,418	0,460	0,088	0,029	67,1	0,0095	0,9712
GRU	0,251	0,374	0,481	0,455	5,5	0,055	0,9347
LSTM	0,378	0,267	0,485	0,455	6,3	0,054	0,9317
MLP	0,429	0,718	0,474	0,449	5,3	0,057	0,9144
BiLSTM	0,395	0,776	0,482	0,454	5,8	0,043	0,8848
1D-CNN	0,258	0,645	0,532	0,463	12,9	0,044	0,8791
Transformer	0,398	0,968	0,401	0,423	-5,5	0,057	0,8744
TCN	0,313	0,950	0,482	0,431	10,6	0,035	0,8519

CNN-LSTM показывает наибольшее снижение ECE (67,1 %) и единственная удовлетворяет NFR-2 ($\text{FPR} \leq 0,01$ при $\text{Recall} \geq 0,85$).

ЭКСПЕРИМЕНТ Е4. СТРЕСС-ТЕСТ С FSM-АГЕНТОМ




Рисунок 6 - Поведение CNN-LSTM на каждом состоянии FSM агента

Таблица 9 - Сводные метрики Е4

Показатель	Значение
Окон / атак	2497 / 1256
F1	0,958
Precision	0,975
Recall	0,942
FPR	0,024
MCC	0,921
PR-AUC	0,979

Все 7 ATTACK-состояний дают recall $\geq 0,88$, 6 из 7 $\geq 0,90$. На NORMAL/DRIFT FPR $\leq 0,030$. Общий уровень Е4 (F1 = 0,958) находится между Е1 in-domain и Е5 при alpha = 0,5, что подтверждает корректность работы pipeline в потоковом режиме.

ЭКСПЕРИМЕНТ E5. УСТОЙЧИВОСТЬ К КОНТРОЛИРУЕМОМУ ДРЕЙФУ




Рисунок 7 - Отношение F1 к интенсивности дрейфа




Рисунок 8 - Отношение PSI к интенсивности дрейфа

Baseline ($\alpha = 0$): F1 = 0,9735 при PSI = 0,21. При максимальной интенсивности $\alpha = 1,0$ $\Delta F1 = 0,082$ (covariate) и 0,066 (concept); модель сохраняет F1 $\geq 0,89$ при всех уровнях дрейфа. drift_alarm срабатывает на 8 из 8 нетривиальных точек (PSI $> 0,25$). NFR-6 выполнено.

Е6 - ПРОИЗВОДИТЕЛЬНОСТЬ; CROSS-EVALUATION

Таблица 10 - Эксплуатационные характеристики моделей (CPU, batch = 1)

Модель	Latency, мс	Throughput, EPS	NFR-3 (≤ 50 мс)	NFR-4 (≥ 1000 EPS)
MLP	0,25	131989	да	да
XGBoost	0,41	68385	да	да
CNN-LSTM	1,16	24560	да	да
Transformer	0,88	22960	да	да
BiLSTM	0,78	13001	да	да
Random Forest	42,66	4980	да	да

Таблица 11 - Метрики cross-evaluation UNSW-NB15 -> CICIDS2017

Показатель	UNSW (in-domain)	CICIDS
F1-max	0,9735	0,7945
F1 на UNSW-калиброванном пороге	---	0,7679
Δ F1 (transfer)	---	0,181
NFR-7 (Δ F1 $\leq 0,20$)	---	выполнено

СООТВЕТСТВИЕ НЕФУНКЦИОНАЛЬНЫМ ТРЕБОВАНИЯМ

Таблица 12 - Сводная таблица выполнения нефункциональных требований целевой моделью CNN-LSTM

ID	Требование	Порог	Факт CNN-LSTM	Статус
NFR-1a	F1 на UNSW-NB15 [1]	$\geq 0,90$	0,9735	выполнено
NFR-1b	PR-AUC на UNSW-NB15 [1]	$\geq 0,95$	0,9945	выполнено
NFR-2	FPR при Recall $\geq 0,85$ [2]	$\leq 0,01$	0,0095	выполнено
NFR-3	Inference latency (batch = 1)	≤ 50 мс	1,16 мс	выполнено
NFR-4	Throughput (batch)	≥ 1000 EPS	24560 EPS	выполнено
NFR-5	Time-to-detect	≤ 1 окно	per-state	выполнено
NFR-6	$\Delta F1$ при PSI $\leq 0,25$ [3]	$\leq 0,10$	≈ 0	выполнено
NFR-7	$\Delta F1$ cross-eval UNSW->CICIDS [4]	$\leq 0,20$	0,181	выполнено
NFR-8	Воспроизводимость одной командой	да	make reproduce	выполнено
NFR-9	σ F1 по seed ($n \geq 3$)	$\leq 0,01$	0,0014	выполнено

1. Moustafa N. UNSW-NB15: A comprehensive data set for network intrusion detection systems / N. Moustafa, J. Slay // Proc. IEEE Military Communications and Information Systems Conf. (MilCIS). 2015. P. 1-6.
2. Guo C. On calibration of modern neural networks / C. Guo [et al.] // Proc. Int. Conf. on Machine Learning (ICML). 2017. P. 1321-1330.
3. Gama J. A survey on concept drift adaptation / J. Gama [et al.] // ACM Computing Surveys. 2014. Vol. 46, № 4. P. 44:1-44:37.
4. Farooq M. A detailed analysis of benchmark datasets for network intrusion detection system / M. Farooq [et al.]. arXiv:2403.17458. 2024.

РАЗРАБОТАННАЯ МЕТОДИКА ОБНАРУЖЕНИЯ

- Сбор и валидация входной телеметрии (CSV, NetFlow v9, IPFIX) по Pydantic-схеме
- Очистка и нормализация: $\log_{1p}$ + robust scaling, обрезка квантилей 0,001 / 0,999
- Кодирование категориальных признаков: one-hot для малой кардинальности, frequency-encoding для большой
- Формирование скользящих окон $W = 32$, $S = 8$ (75 % перекрытие), last-агрегация меток
- Нейросетевой инференс: CNN-LSTM (Conv1D x2 + BiLSTM + Attention pool + LayerNorm)
- Калибровка вероятностей (T-scaling) и порога τ под target-FPR = 0,01 на val
- Принятие решения $\hat{y} = I[p \geq \tau]$; формирование скоринга по окну
- Формирование алертов: severity по нормированному превышению порога и временная дедупликация 5 с
- Мониторинг дрейфа: PSI / KL / MMD относительно эталонной выборки; drift_alarm при $PSI > 0,25$
- Экспорт алертов в JSON Lines, REST-API, Streamlit-дэшборд для интеграции в SOC

РЕЗУЛЬТАТЫ РАБОТЫ

- Проведен аналитический обзор предметной области обнаружения аномалий и несанкционированных действий в корпоративных сетях; выполнен сравнительный анализ 9 нейросетевых архитектур и 10 публично доступных датасетов NIDS по балльной шкале
- Формализованы функциональные и нефункциональные требования к системе обнаружения (10 FR + 10 NFR) и определены количественные критерии качества с числовыми порогами
- Спроектированы методика обнаружения аномальной активности из 10 шагов и архитектура нейросетевого детектора CNN-LSTM (Conv1D x 2 + BiLSTM + Attention pool + LayerNorm)
- Разработана подсистема предобработки и формирования обучающих и тестовых выборок (log1p + robust scaling, one-hot / frequency-encoding, скользящие окна $W = 32$, $S = 8$)
- Реализована и обучена нейросетевая модель детекции в едином программном регистре с 15 моделями-кандидатами; целевая CNN-LSTM достигла $F1 = 0,9735$ и $PR-AUC = 0,9945$
- Разработан конечно-автоматный агент активного тестирования (11 состояний) с библиотекой из 7 параметризованных шаблонов и инжектором дрейфа трёх типов (covariate / prior / concept)
- Реализован программный прототип системы обнаружения в реальном времени с REST-интерфейсом (FastAPI) и визуальной панелью (Streamlit)
- Проведена экспериментальная проверка эффективности методики (6 экспериментов E1-E6 и cross-evaluation на CICIDS2017) и подтверждена гипотеза исследования; FPR в 11 раз ниже XGBoost при сопоставимом F1
- Выполнена оценка эксплуатационных характеристик (latency 1,16 мс/окно, throughput 24 560 EPS на CPU) и оформлены итоговые материалы

QR-код НА РЕПОЗИТОРИЙ С ИСХОДНЫМ КОДОМ

